# 03. 데이터 마이닝과 dplyr 패키지

3주차

성현곤

충북대학교 도시공학과
Dept.of URBAN ENGINEERING

# 목차

보완(s83~s99)

# 데이터의 종류와 함수

- R은 거의 모든 자료 활용 가능
  - 내장 데이터
    - 기본 데이터세트
  - 외장 데이터
    - 일반 텍스트 파일
    - 엑셀 스프레드 시트
    - 기타 각종 프로그램 데이터 파일
    - 데이터 베이스
    - 웹페이지
    - 비정형 텍스트 파일 등
- 기본 데이터 세트(내장 데이터)
  - R 데이터 세트
    - 리스트와 간단한 설명 확인
    - help(package= " datasets " )
  - 패키지와 함께 있는 파일

```
> ### 내장 데이터 불러오기(적재하기)
> library(help=datasets) # 내장 데이터 목록보기
```

패키지 'datasets'에 대한 정보

설명:

```
Package:        datasets
Version:        3.5.3
Priority:       base
Title:          The R Datasets Package
Author:         R Core Team and contributors worldwide
Maintainer:     R Core Team <R-core@r-project.org>
Description:    Base R datasets.
License:        Part of R 3.5.3
Built:          R 3.5.3; ; 2019-03-11 08:33:40 UTC; windows
```

인덱스:

```
AirPassengers           Monthly Airline Passenger Numbers 1949-1960
BJsales                 Sales Data with Leading Indicator
BOD                     Biochemical Oxygen Demand
CO2                     Carbon Dioxide Uptake in Grass Plants
ChickWeight             Weight versus age of chicks on different diets
DNase                   Elisa assay of DNase
EuStockMarkets          Daily Closing Prices of Major European Stock
                        Indices, 1991-1998
Formaldehyde            Determination of Formaldehyde
HairEyeColor            Hair and Eye Color of Statistics Students
Harman23.cor            Harman Example 2.3
Harman74.cor            Harman Example 7.4
Indometh                Pharmacokinetics of Indomethacin
InsectSprays            Effectiveness of Insect Sprays
JohnsonJohnson          Quarterly Earnings per Johnson & Johnson Share
LakeHuron               Level of Lake Huron 1875-1972
LifeCycleSavings        Intercountry Life-Cycle Savings Data
Loblolly                Growth of Loblolly pine trees
Nile                    Flow of the River Nile
Orange                  Growth of Orange Trees
```

# 데이터의 종류와 함수

- 외장 데이터 불러오기와 함수
  - 외장 데이터 종류와 함수

| Format | Typical Extension | Import Package | Export Package | Installed by Default |
|---|---|---|---|---|
| Comma-separated data | .csv | data.table | data.table | Yes |
| Pipe-separated data | .psv | data.table | data.table | Yes |
| Tab-separated data | .tsv | data.table | data.table | Yes |
| SAS | .sas7bdat | haven | haven | Yes |
| SPSS | .sav | haven | haven | Yes |
| Stata | .dta | haven | haven | Yes |
| SAS XPORT | .xpt | haven | haven | Yes |
| SPSS Portable | .por | haven | | Yes |
| Excel | .xls | readxl | | Yes |
| Excel | .xlsx | readxl | openxlsx | Yes |
| R syntax | .R | base | base | Yes |
| Saved R objects | .RData, .rda | base | base | Yes |
| Serialized R objects | .rds | base | base | Yes |
| Epiinfo | .rec | foreign | | Yes |
| Minitab | .mtp | foreign | | Yes |
| Systat | .syd | foreign | | Yes |
| "XBASE" database files | .dbf | foreign | foreign | Yes |
| Weka Attribute-Relation File Format | .arff | foreign | foreign | Yes |
| Data Interchange Format | .dif | utils | | Yes |
| Fortran data | no recognized extension | utils | | Yes |
| Fixed-width format data | .fwf | utils | utils | Yes |
| gzip comma-separated data | .csv.gz | utils | utils | Yes |
| CSVY (CSV + YAML metadata header) | .csvy | csvy | csvy | No |
| EViews | .wf1 | hexView | | No |
| Feather R/Python interchange format | .feather | feather | feather | No |
| Fast Storage | .fst | fst | fst | No |
| JSON | .json | jsonlite | jsonlite | No |
| Matlab | .mat | rmatio | rmatio | No |
| OpenDocument Spreadsheet | .ods | readODS | readODS | No |
| HTML Tables | .html | xml2 | xml2 | No |
| Shallow XML documents | .xml | xml2 | xml2 | No |
| YAML | .yml | yaml | yaml | No |
| Clipboard | default is tsv | clipr | clipr | No |
| Google Sheets | as Comma-separated data | | | |

# 내장 데이터 불러오기

- 기본 데이터 세트(내장 데이터)
  - iris # 데이터 세트 이름 입력으로 바로 사용가능
  - co2 # 바로 함수 또는 명령어로 활용 가능
    - str(co2)

```
> CO2
Grouped Data: uptake ~ conc | Plant
   Plant        Type  Treatment conc uptake
1    Qn1      Quebec nonchilled   95   16.0
2    Qn1      Quebec nonchilled  175   30.4
3    Qn1      Quebec nonchilled  250   34.8
4    Qn1      Quebec nonchilled  350   37.2
5    Qn1      Quebec nonchilled  500   35.3
6    Qn1      Quebec nonchilled  675   39.2
7    Qn1      Quebec nonchilled 1000   39.7
8    Qn2      Quebec nonchilled   95   13.6
9    Qn2      Quebec nonchilled  175   27.3
10   Qn2      Quebec nonchilled  250   37.1
11   Qn2      Quebec nonchilled  350   41.8
12   Qn2      Quebec nonchilled  500   40.6
13   Qn2      Quebec nonchilled  675   41.4
```

```
> iris # 데이터 세트 이름 입력으로 바로 사용가능
   Sepal.Length Sepal.Width Petal.Length Petal.Width    Species
1           5.1         3.5          1.4         0.2     setosa
2           4.9         3.0          1.4         0.2     setosa
3           4.7         3.2          1.3         0.2     setosa
4           4.6         3.1          1.5         0.2     setosa
5           5.0         3.6          1.4         0.2     setosa
6           5.4         3.9          1.7         0.4     setosa
7           4.6         3.4          1.4         0.3     setosa
8           5.0         3.4          1.5         0.2     setosa
9           4.4         2.9          1.4         0.2     setosa
10          4.9         3.1          1.5         0.1     setosa
11          5.4         3.7          1.5         0.2     setosa
12          4.8         3.4          1.6         0.2     setosa
13          4.8         3.0          1.4         0.1     setosa
14          4.3         3.0          1.1         0.1     setosa
15          5.8         4.0          1.2         0.2     setosa
16          5.7         4.4          1.5         0.4     setosa
17          5.4         3.9          1.3         0.4     setosa
18          5.1         3.5          1.4         0.3     setosa
19          5.7         3.8          1.7         0.3     setosa
20          5.1         3.8          1.5         0.3     setosa
```

```
> str(CO2) # 데이터 구조 확인하기
Classes 'nfnGroupedData', 'nfGroupedData', 'groupedDat
 $ Plant    : Ord.factor w/ 12 levels "Qn1"<"Qn2"<"Qn3"
 $ Type     : Factor w/ 2 levels "Quebec","Mississippi"
 $ Treatment: Factor w/ 2 levels "nonchilled","chilled"
 $ conc     : num  95 175 250 350 500 675 1000 95 175
 $ uptake   : num  16 30.4 34.8 37.2 35.3 39.2 39.7 13
 - attr(*, "formula")=Class 'formula'  language uptake
  .. ..- attr(*, ".Environment")=<environment: R_EmptyE
 - attr(*, "outer")=Class 'formula'  language ~Treatmer
  .. ..- attr(*, ".Environment")=<environment: R_EmptyE
 - attr(*, "labels")=List of 2
  ..$ x: chr "Ambient carbon dioxide concentration"
```

# 작업경로(폴더) 확인 및 변경

- 작업 경로의 확인 및 변경
  - 외장 데이터는 불러오고자 하는 파일과 그 경로를 알아야 함
  - 작업 경로(폴더) 내에서는 경로 설정 불필요
- 현재 작업 디렉토리 확인: getwd()
- 작업 디렉토리의 변경 설정: setwd()
  - 폴더(경로) 구분자 사용 주의
    - '\' 는 사용 불가능(오류 발생)
    - '/' 또는 '\\' 사용
  - 파일 디레토리가 루트 디렉토리에서 시작하지 않을 경우 현재 디렉토리에서 시작 가정
- 작업 디렉토리의 파일 확인: list.files()

```
> #### 작업경로(폴더) 확인하고 변경하기
> ?getwd # 현재 설정된 경로 확인
> getwd()
[1] "E:/강의/수치해석/3주차_R_데이터마이닝_dplyr패키지"
> ?setwd # 앞으로 작업하고자 하는 폴더 또는 그 파일이 있는 폴더의 경로로 설정
> setwd("E:\강의\수치해석\3주차_R_데이터마이닝_dplyr패키지") # 오류 발생
Error: '\?' is an unrecognized escape in character string starting ""E:\?
> setwd("E:\\강의\\수치해석\\3주차_R_데이터마이닝_dplyr패키지")
> setwd("E:/강의/수치해석/3주차_R_데이터마이닝_dplyr패키지")
> getwd() # 바뀐 경로 확인
[1] "E:/강의/수치해석/3주차_R_데이터마이닝_dplyr패키지"
```

```
> list.files() # 작업 폴더(경로) 내 파일 목록 확인하기
 [1] "~$03_R 데이터마이닝과 dplyr 패키지_v1_2019-09-08.pptx"
 [2] "~$선수과목강좌_05_R_컴퓨터프로그래밍_03_R_programming_practi
 [3] "03_R 데이터마이닝과 dplyr 패키지_v1_2019-09-08.pptx"
 [4] "03_데이터마이닝과 dplyr 패키지_v1_2019-09-06.R"
 [5] "d_sigungu.xlsx"
 [6] "data_apt_sale_충북.txt"
 [7] "data_by_sigungu.csv"
 [8] "data_by_sigungu.xlsx"
 [9] "data_by_sigungu_2018.csv"
[10] "data_by_sigungu_2018.xlsx"
[11] "데이터_아파트(매매)_실거래가_충남대전세종.csv"
[12] "데이터_아파트(매매)_실거래가_충남대전세종.xlsx"
[13] "데이터_아파트매매가격.csv"
[14] "데이터_아파트매매가격.xlsx"
[15] "선수과목강좌_04_R_시작하기_입문_v2.docx"
```

# 데이터 불러오기와 저장하기

## 작업경로(폴더) 확인 및 변경

- Rstudio의 메뉴바로 설정

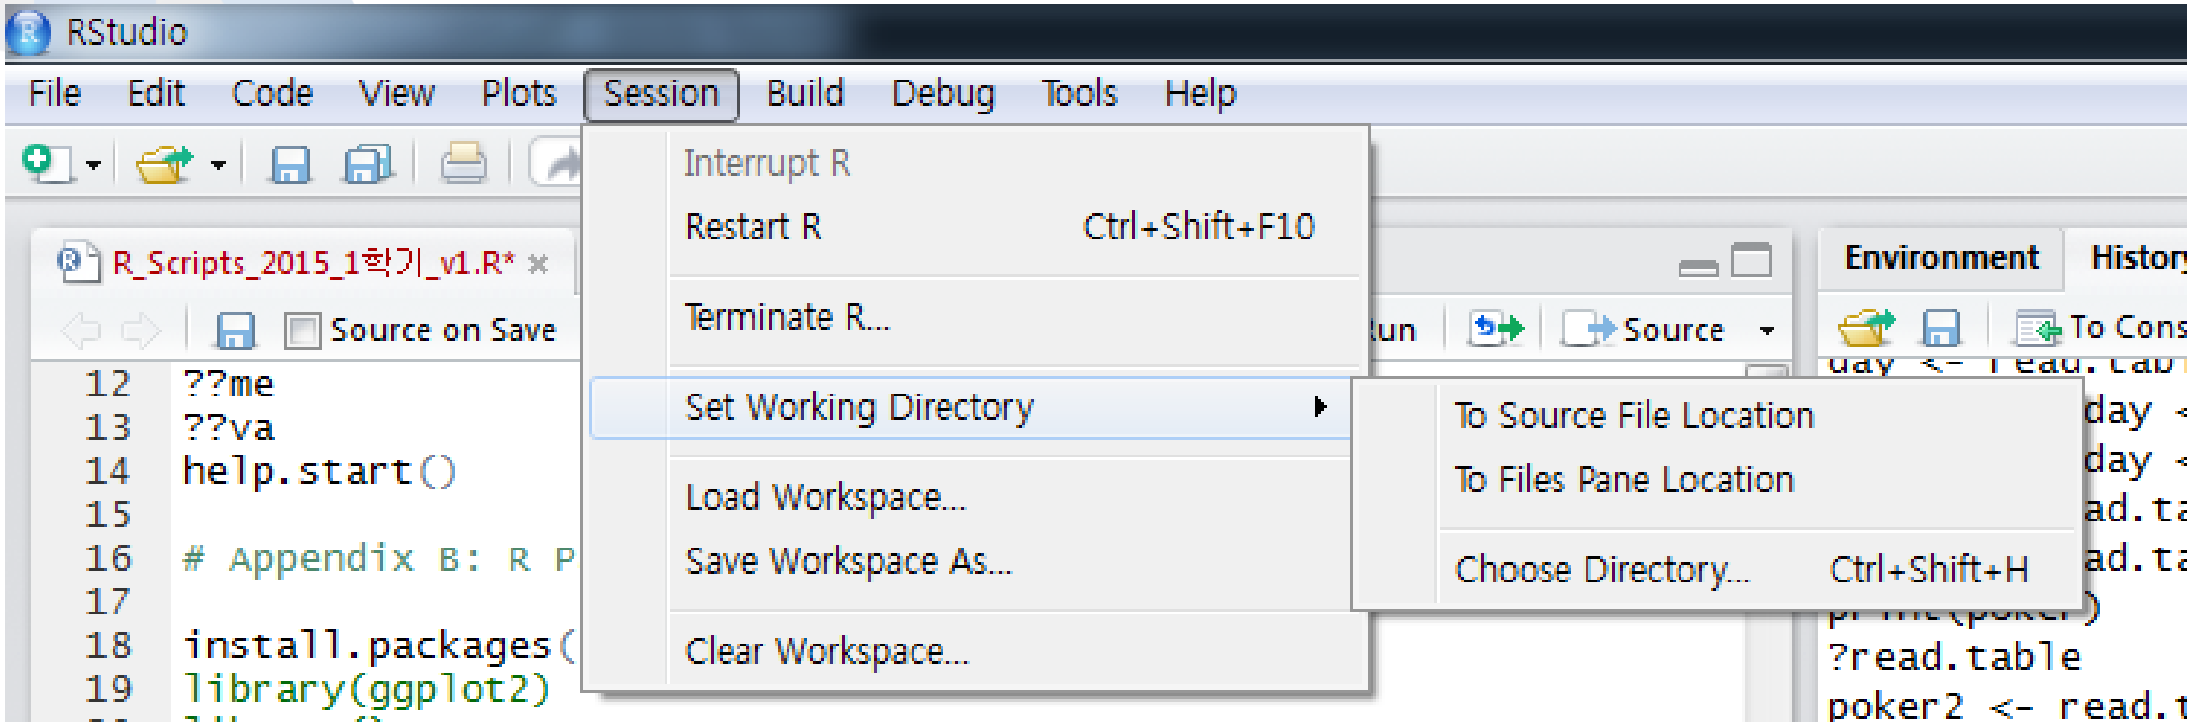

# 외장 데이터 불러오기와 저장하기

- 일반 텍스트 파일
  - 일반 문서에 테이블 형태로 데이터 저장
    - 콤마, 탭, |, 혹은 문자 또는 기호로 각각의 칸을 구분
    - 혼란을 피하기 위하여 하나의 파일에 하나의 기본 구분 규칙 적용
    - 모든 텍스트 파일은 “.txt” 확장자
    - 때로는 구분 기호의 종류를 확실히 하기 위하여 특별한 확장자 사용
      - 예: 콤마 구분기호 파일 확장자 = .csv(comma-separeted value)
- 일반 텍스트 파일
  - 불러오기: read.table() 함수
  - 저장하기: write.table() 함수

```
> #### 텍스트 파일 불러오고 저장하기
> ?read.table
> ?read.csv
```

read.table {utils} R Documentation

Data Input

Description

Reads a file in table format and creates a data frame from it, with cases corresponding to lines and variables to fields in the file.

Usage

```
read.table(file, header = FALSE, sep = "", quote = "\"'",
           dec = ".", numerals = c("allow.loss", "warn.loss", "no.loss"),
           row.names, col.names, as.is = !stringsAsFactors,
           na.strings = "NA", colClasses = NA, nrows = -1,
           skip = 0, check.names = TRUE, fill = !blank.lines.skip,
           strip.white = FALSE, blank.lines.skip = TRUE,
           comment.char = "#",
           allowEscapes = FALSE, flush = FALSE,
           stringsAsFactors = default.stringsAsFactors(),
           fileEncoding = "", encoding = "unknown", text, skipNul = FALSE)

read.csv(file, header = TRUE, sep = ",", quote = "\"",
         dec = ".", fill = TRUE, comment.char = "", ...)

read.csv2(file, header = TRUE, sep = ";", quote = "\"",
          dec = ",", fill = TRUE, comment.char = "", ...)
```

```
> ?write.table
> ?write.csv
```

write.table prints its required argument x (after converting it to a data frame if it is not one nor a matrix) to a file or connection.

Usage

```
write.table(x, file = "", append = FALSE, quote = TRUE, sep = " ",
            eol = "\n", na = "NA", dec = ".", row.names = TRUE,
            col.names = TRUE, qmethod = c("escape", "double"),
            fileEncoding = "")

write.csv(...)
write.csv2(...)
```

# 외장 데이터 불러오기와 저장하기

- 일반 텍스트 파일
- read.table() 인수(arguments)
  - file, header, sep, quote, na.string, skip, nrow, ……
    - (file =) "파일경로/파일이름.확장자"
    - sep: 파일 구분기호 지정
    - header: 첫 번째 변숫값이 변수이름인지 지정
      - header=TRUE, FALSE
    - na.string: 결측기호 표시 및 확인
      - na.string="." # "."을 NA로 표시
    - skip 또는 nrow: 데이터 세트 특정구간 부터 시작하여 마치기
      - skip : 몇 줄 부터 건너뛰어 데이터 읽어드림
      - nrow : 정해진 줄 수 만큼 읽고 마침
        - 첫번째 header행은 nrow에 포함되지 않음

```
> #### 텍스트 파일 불러오고 저장하기
> ?read.table
> ?read.csv
```

read.table {utils} R Documentati

## Data Input

### Description

Reads a file in table format and creates a data frame from it, with cases corresponding to lines and variables to fields in the file.

### Usage

```
read.table(file, header = FALSE, sep = "", quote = "\"'",
           dec = ".", numerals = c("allow.loss", "warn.loss", "no.loss"),
           row.names, col.names, as.is = !stringsAsFactors,
           na.strings = "NA", colClasses = NA, nrows = -1,
           skip = 0, check.names = TRUE, fill = !blank.lines.skip,
           strip.white = FALSE, blank.lines.skip = TRUE,
           comment.char = "#",
           allowEscapes = FALSE, flush = FALSE,
           stringsAsFactors = default.stringsAsFactors(),
           fileEncoding = "", encoding = "unknown", text, skipNul = FALSE)

read.csv(file, header = TRUE, sep = ",", quote = "\"",
         dec = ".", fill = TRUE, comment.char = "", ...)

read.csv2(file, header = TRUE, sep = ";", quote = "\"",
          dec = ",", fill = TRUE, comment.char = "", ...)
```

# 외장 데이터 불러오기와 저장하기

- 데이터의 숫자가 아닌 문자열을 불러 들일 때, R은 자동으로 요인으로 불러들임
  - 한 개의 파일에서 요인이 아닌 문자로 불러들이고자 할 때의 인수 옵션
    - “stringAsFactors=FALSE” 옵션 지정

```
House <- read.table(“I:/R_analysis/house.txt", sep=",", header=TRUE, stringAsFactors=FALSE)
```

  - 여러 개의 데이터 세터를 불러 들일 경우,
    - options(stringAsFactors=FALSE)
- 요인으로 불러들이고자 할 때,
  - 기본(default)이므로, 설정하지 않아도 됨
  - 또는 stringAsFactors=TRUE

# 외장 데이터 불러오고 저장하기

- 충청북도 아파트 실거래가 자료(2018.09~2019.08.31) 불러오기

```
> apt_sale <- read.table('데이터_아파트매매가격.csv', # 현재 작업 폴더에 있는 파일 이름
+                        sep=","  # 구분자 = ","
+                        , header = TRUE,  # 첫행을 변수명으로
+                        stringsAsFactors = FALSE) # 명목변수(열)은 요인이 아닌 문자로 불러오기

> apt_sale <- read.table(file.choose()) # 파일 이름을 모를 때 사용 또는 list.files() 함수 사용하여 확인
```

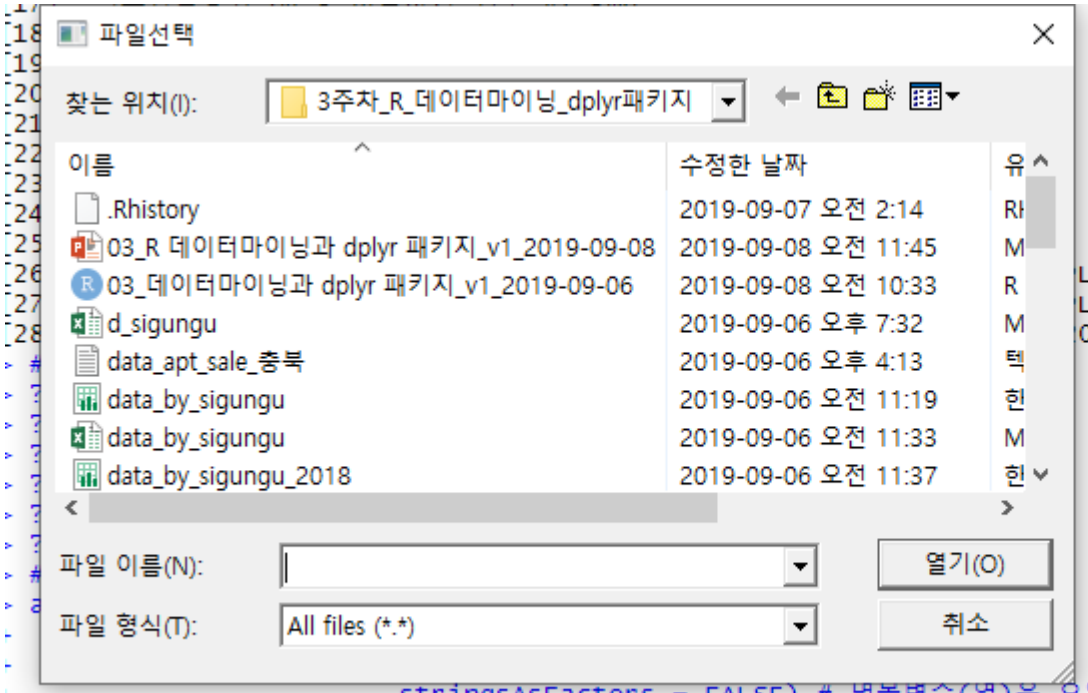

# 외장 데이터 불러오고 저장하기

- 데이터 확인하기
  - 데이터 구조: str()

```
> str(apt_sale) # 데이터 구조 확인하기
'data.frame':   13309 obs. of  14 variables:
 $ id              : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price       : int  4800 4500 4000 4000 4000 4000 4000 4000 4000
 $ area_m2         : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8
 $ floor_no        : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built      : int  1998 1998 1998 1998 1998 1998 1998 1998 1998
 $ ym_sale         : int  201811 201811 201812 201812 201812 201812 201
 $ day_sale        : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban           : chr  "읍" "읍" "읍" "읍" ...
 $ apt_complex     : chr  "두진백로" "두진백로" "두진백로" "두진백로" ...
 $ address         : chr  "충청북도 괴산군 괴산읍 대사리" "충청북도 괴산군 괴산
 $ address_bunji   : chr  "177-1" "177-1" "177-1" "177-1" ...
 $ address_sido    : chr  "충청북도" "충청북도" "충청북도" "충청북도" ...
 $ address_sigungu: chr  "괴산군" "괴산군" "괴산군" "괴산군" ...
 $ address_dong    : chr  "괴산읍" "괴산읍" "괴산읍" "괴산읍" ...
```

  - 데이터 열 속성 확인
    - is.character()
    - is.factor()

```
> is.character(apt_sale$urban) # 데이터의 열($, 키)로 내부 열 urban 문자인 지 여부 확인
[1] TRUE
> apt_sale$urban <- as.factor(apt_sale$urban) # 문자형 변수를 요인형 변수로 변환하기
> is.character(apt_sale$urban) ; is.factor(apt_sale$urban) # 문자, 요인변수 확인, ";
[1] FALSE
[1] TRUE
```

  - 데이터 수정
    - 요인으로 데이터 변환: as.factor()
- ";"로 두개 명령문 한줄에서 동시 실행 가능

# 외장 데이터 불러오고 저장하기

- 일반 텍스트 파일
  - 저장하기
    - write.table()
      - 기존 파일명이 같은 경우에는 덮어쓰기가 되므로, 저장할 파일 이름 명명시 주의 필요

```
> #****** 데이터 텍스트 파이로 저장하기
> write.table(apt_sale, # 저장할 객체(데이터) 이름
+             'data_apt_sale_충북.txt', # 저장하고자 하는 파일 이름 명명(다른 폴더 저장시 해당 경로 설정)
+             sep=",") # 구분자 설정
```

  - 저장한 파일 확인하기
    - file.exists()
    - list.files()

```
> file.exists('data_apt_sale_충북.txt')
[1] TRUE
> list.files()
 [1] "~$03_R 데이터마이닝과 dplyr 패키지_v2_2019-09-08.pptx"
 [2] "~$선수과목강좌_05_R_컴퓨터프로그래밍_03_R_programming_pr
 [3] "03_R 데이터마이닝과 dplyr 패키지_v1_2019-09-08.pptx"
 [4] "03_R 데이터마이닝과 dplyr 패키지_v2_2019-09-08.pptx"
 [5] "03_데이터마이닝과 dplyr 패키지_v1_2019-09-06.R"
 [6] "d_sigungu.xlsx"
 [7] "data_apt_sale_충북.txt"
 [8] "data_by_sigungu.csv"
 [9] "data_by_sigungu.xlsx"
```

# 데이터 불러오기와 저장하기

## 외장 데이터 불러오고 저

```
# The easiest way to get readr is to install the whole tidyverse:
install.packages("tidyverse")

# Alternatively, install just readr:
install.packages("readr")

# Usage
library(tidyverse)  or  library(readr)
```

- 일반 텍스트 파일
  - “readr” 패키지로 데이터 불러오기와 저장하기 활용

```
> install.packages("readr")
WARNING: Rtools is required to build R packages but
fore proceeding:

https://cran.rstudio.com/bin/windows/Rtools/
Installing package into 'C:/Users/hgs_home/Documents
(as 'lib' is unspecified)
trying URL 'https://cran.rstudio.com/bin/windows/con
Content type 'application/zip' length 1585643 bytes
downloaded 1.5 MB

package 'readr' successfully unpacked and MD5 sums c

The downloaded binary packages are in
        C:\Users\Public\Documents\ESTsoft\CreatorTem
> library(readr)
> ?readr
```

### readr: Read Rectangular Text Data

**Description**

The goal of 'readr' is to provide a fast and friendly way to read rectangular data (like 'csv', 'tsv', and 'fwf'). It is designed to flexibly parse many types of data found in the wild, while still cleanly failing when data unexpectedly changes.

**Author(s)**

**Maintainer**: Jim Hester james.hester@rstudio.com

Authors:

- Hadley Wickham hadley@rstudio.com
- Romain Francois

Other contributors:

- R Core Team (Date time code adapted from R) [contributor]
- RStudio [copyright holder, funder]

# 외장 데이터 불러오고 저장하기

- 일반 텍스트 파일
  - “readr” 패키지로 데이터 불러오기 활용
    - The goal of readr is to provide **a fast** and **friendly way** to read rectangular data (like csv, tsv, and fwf).
    - readr supports seven file formats with seven read_ functions:
      - read_csv(): comma separated (CSV) files
      - read_tsv(): tab separated files
      - read_delim(): general delimited files
      - read_fwf(): fixed width files
      - read_table(): tabular files where columns are separated by white-space.
      - read_log(): web log files

# 외장 데이터 불러오고 저장하기

- "readr" 패키지로 데이터 불러오기
  - 데이터 불러오기: read_csv()

```
> apt_sale2 <- read_csv('데이터_아파트매매가격.csv', # 파일 경로와 이름
+                       locale=locale('ko',encoding='euc-kr'))  # 한글 설정
Parsed with column specification:
cols(
  id = col_double(),
  apt_price = col_double(),
  area_m2 = col_double(),
  floor_no = col_double(),
  year_built = col_double(),
  ym_sale = col_double(),
  day_sale = col_double(),
  urban = col_character(),
```

  - 데이터 확인하기: head(), str(), View()

```
> head(apt_sale2) # 6째 행까지 데이터 확인
# A tibble: 6 x 14
     id apt_price area_m2 floor_no year_built ym_sale day_sale urb
  <dbl>     <dbl>   <dbl>    <dbl>      <dbl>   <dbl>    <dbl> <ch
1     1      4800    39.8        2       1998  201811        6 읍
2     2      4500    39.8        6       1998  201811       13 읍
3     3      4000    39.8        7       1998  201812       10 읍
4     4      4000    39.8        9       1998  201812       10 읍
5     5      4000    39.8        3       1998  201812       10 읍
6     6      4000    39.8        7       1998  201812       10 읍
# ... with 1 more variable: address_dong <chr>
> str(apt_sale2) # 데이터 구조 확인하기
Classes 'spec_tbl_df', 'tbl_df', 'tbl' and 'data.frame':        13
 $ id           : num  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price    : num  4800 4500 4000 4000 4000 4000 4000 4000 4
 $ area_m2      : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 3
 $ floor_no     : num  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built   : num  1998 1998 1998 1998 1998 ...
 $ ym_sale      : num  201811 201811 201812 201812 201812 ...
 $ day_sale     : num  6 13 10 10 10 10 10 10 10 10 ...
 $ urban        : chr  "읍" "읍" "읍" "읍"
```

```
> view(apt_sale2) # 새로운 창에서 데이터 확인
```

03_데이터마이닝과 dplyr 패키지_v1_20... * | apt_sale2 | 컴퓨터프로그래밍_03_R_programming_...

Filter

| | id | apt_price | area_m2 | floor_no | year_built | ym_sale | day_sale | urban | apt_complex |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | 4800 | 39.8000 | 2 | 1998 | 201811 | 6 | 읍 | 두진백로 |
| 2 | 2 | 4500 | 39.8000 | 6 | 1998 | 201811 | 13 | 읍 | 두진백로 |
| 3 | 3 | 4000 | 39.8000 | 7 | 1998 | 201812 | 10 | 읍 | 두진백로 |
| 4 | 4 | 4000 | 39.8000 | 9 | 1998 | 201812 | 10 | 읍 | 두진백로 |
| 5 | 5 | 4000 | 39.8000 | 3 | 1998 | 201812 | 10 | 읍 | 두진백로 |
| 6 | 6 | 4000 | 39.8000 | 7 | 1998 | 201812 | 10 | 읍 | 두진백로 |
| 7 | 7 | 4000 | 39.8000 | 5 | 1998 | 201812 | 10 | 읍 | 두진백로 |

# 외장 데이터 불러오고 저장하기

- “readr” 패키지로 데이터 저장하기
  - write_csv()

## Write a data frame to a delimited file

### Description

This is about twice as fast as write.csv(), and never writes row names.
output_column() is a generic method used to coerce columns to suitable output.

### Usage

```
write_delim(x, path, delim = " ", na = "NA", append = FALSE,
  col_names = !append, quote_escape = "double")

write_csv(x, path, na = "NA", append = FALSE, col_names = !append,
  quote_escape = "double")
```

```
> write_csv(apt_sale2, # 저장할 객체
+           "test.csv") # 저장할 파일 이름 명명
> file.exists('test.csv')
[1] TRUE
```

# 외장 데이터 불러오고 저장하기

- 엑셀 스프레드 시트(파일) 불러오기
  - 엑셀 파일 입출력을 위한 패키지들 많음
    - "readxl"과 "xlsx" 패키지 활용
  - Importing Excel files into R using readxl package
    - install.packages("readxl") # 엑셀 불러오고 저장하기 패키지 설치
    - library("readxl") # 엑셀 패키지 불러오기(요청) 또는
    - library(readxl)

```
> install.packages("readxl") # 엑셀 불러오고 저장하기 패키지 설치
Installing package into 'C:/Users/hyun/Documents/R/win-library/3.6'
(as 'lib' is unspecified)
also installing the dependencies 'magrittr', 'rematch', 'prettyunits', 'cellran

trying URL 'https://cran.rstudio.com/bin/windows/contrib/3.6/magrittr_1.5.zip'
Content type 'application/zip' length 157877 bytes (154 KB)
downloaded 154 KB
```

```
> library("readxl") # 엑셀 패키지 불러오기(요청)
> library(readxl)
```

  - R 프로그램 자체는 자바가 없어도 실행이 가능하지만 대부분의 패키지를 사용하기 위해서는 자바가 필요
    - https://www.java.com/ko/
    - 32bit vs. 64bit : 64 bit 버전 수동 설치
    - https://www.java.com/en/download/manual.jsp
  - Importing Excel files using xlsx package
    - install.packages("xlsx")
    - library("xlsx")

```
> install.packages("xlsx")
WARNING: Rtools is required to build R packages but is not currently instal

https://cran.rstudio.com/bin/windows/Rtools/
trying URL 'https://cran.rstudio.com/bin/windows/contrib/3.6/xlsx_0.6.1.zip
Content type 'application/zip' length 460695 bytes (449 KB)
downloaded 449 KB

package 'xlsx' successfully unpacked and MD5 sums checked

The downloaded binary packages are in
        C:\Users\user\AppData\Local\Temp\RtmpcNodCH\downloaded_packages
> library(xlsx) # 자바(java)와 매칭되어야 하므로, 최신 자바버전 및 64bit 설치 필요
```

# 외장 데이터 불러오고 저장하기

- readxl package로 엑셀 파일 불러오기

```
> data_sigungu <- read.xlsx("data_by_sigungu_2018.xlsx", # file: 파일 경로와 이름
+                           sheetName="data", # 불러들일 시트 이름
+                           header=TRUE, # 첫행을 열의 변수명으로 함
+                           encoding="UTF-8") # 한글 코드 인식
```

```
> str(data_sigungu) # 데이터 구조 확인하기
'data.frame':   261 obs. of  16 variables:
 $ id                 : num  1 2 3 4 5 6 7 8 9 10 ...
 $ sido               : Factor w/ 17 levels "강원도","경기도",..: 9 9 9 9
 $ sigungu            : Factor w/ 236 levels "가평군","강남구",..: 190 191
 $ area               : num  23.91 9.96 21.87 16.86 17.06 ...
 $ pop_density        : num  6387 12574 10529 17750 20935 ...
 $ pop_tot            : num  154770 125709 229161 304808 357703 ...
 $ pop_male           : num  75967 62253 110878 150368 174414 ...
 $ pop_female         : num  78803 63456 118283 154440 183289 ...
 $ age_average        : Factor w/ 132 levels "-","35.9","36.2",..: 48 54
 $ r_aged             : num  17.1 17.1 16 13.6 12.5 ...
 $ pop_net_move       : num  -204 143 -89 57 -608 -469 -429 -716 -521 -3
 $ housing            : num  45729 40177 71680 87830 85638 ...
 $ apt_sale_price     : num  102 104 105 105 104 ...
 $ apt_junse_price    : num  102 101 100 100 102 ...
 $ car                : num  0.33 0.41 0.34 0.34 0.28 0.28 0.28 0.27 0.2
 $ accident_per_1000car: num  18.82 18.72 14.64 8.54 8.72 ...
```

```
> ?read_excel
```

## Read xls and xlsx files

### Description

Read xls and xlsx files

`read_excel()` calls `excel_format()` to determine if `path` is xls or xlsx, based on the file extension and the file itself, in that order. Use `read_xls()` and `read_xlsx()` directly if you know better and want to prevent such guessing.

### Usage

```
read_excel(path, sheet = NULL, range = NULL, col_names = TRUE,
  col_types = NULL, na = "", trim_ws = TRUE, skip = 0,
  n_max = Inf, guess_max = min(1000, n_max),
  progress = readxl_progress(), .name_repair = "unique")

read_xls(path, sheet = NULL, range = NULL, col_names = TRUE,
  col_types = NULL, na = "", trim_ws = TRUE, skip = 0,
  n_max = Inf, guess_max = min(1000, n_max),
  progress = readxl_progress(), .name_repair = "unique")

read_xlsx(path, sheet = NULL, range = NULL, col_names = TRUE,
  col_types = NULL, na = "", trim_ws = TRUE, skip = 0,
  n_max = Inf, guess_max = min(1000, n_max),
  progress = readxl_progress(), .name_repair = "unique")
```

# 외장 데이터 불러오고 저장하기

- xlsx package로 엑셀 파일 불러오기
  - read_xlsx2() : 불러들이는 속도 빠름. 그러나 요인으로 인식

```
> data_sigungu2 <- read.xlsx2("data_by_sigungu_2018.xlsx", # file: 파일 경로와 이름
+                             sheetIndex= 1, # 첫번 째 시트를 불러들임
+                             header=TRUE) # 첫행을 열의 변수명으로 함
> str(data_sigungu2) # 모든 변수들이 요인(Factor)으로 인식됨
'data.frame':   261 obs. of  16 variables:
 $ id                : Factor w/ 261 levels "1","10","100",..: 1 112 185 196 207 2
 $ sido              : Factor w/ 17 levels "강원도","경기도",..: 9 9 9 9 9 9 9 9 9 9
 $ sigungu           : Factor w/ 236 levels "가평군","강남구",..: 190 191 161 110 28
 $ area              : Factor w/ 229 levels "","10.21","1009.24",..: 57 215 52 34
 $ pop_density       : Factor w/ 229 levels "","10212.16",..: 173 23 8 64 85 94 89
 $ pop_tot           : Factor w/ 261 levels "1004081","100615",..: 29 23 62 113 14
 $ pop_male          : Factor w/ 261 levels "100613","102876",..: 241 235 11 62 89
 $ pop_female        : Factor w/ 261 levels "100652","101050",..: 243 235 26 66 95
 $ age_average       : Factor w/ 132 levels "-","35.9","36.2",..: 48 54 48 40 36 4
 $ r_aged            : Factor w/ 214 levels "","10.18","10.88",..: 83 82 73 44 29
 $ pop_net_move      : Factor w/ 193 levels "","-1","-105",..: 25 114 101 167 85 6
```

  - 숫자형 변수로 변환: as.numeric()

```
> data_sigungu2$area <- as.numeric(data_sigungu2$area) # 시군구 면적: 요인형 변수를 숫자형 변수로 변환하기
> data_sigungu2$pop_density <- as.numeric(data_sigungu2$pop_density) # 인구밀도 : 요인형 변수를 숫자형 변수로 변환하기
> str(data_sigungu2)
'data.frame':   261 obs. of  16 variables:
 $ id                : Factor w/ 261 levels "1","10","100",..: 1 112 185 196 207 218 229 240 251 2 ...
 $ sido              : Factor w/ 17 levels "강원도","경기도",..: 9 9 9 9 9 9 9 9 9 9 ...
 $ sigungu           : Factor w/ 236 levels "가평군","강남구",..: 190 191 161 110 28 67 192 111 5 64 ...
 $ area              : num  57 215 52 34 36 25 43 60 55 50 ...
 $ pop_density       : num  173 23 8 64 85 94 89 73 32 56 ...
 $ pop_tot           : Factor w/ 261 levels "1004081","100615",..: 29 23 62 113 142 140 162 182 120 134 ...
 $ pop_male          : Factor w/ 261 levels "100613","102876",..: 241 235 11 62 89 91 114 125 70 79 ...
```

# 외장 데이터 불러오고 저장하기

- 엑셀 파일 저장하고 확인하기
  - 저장하기: write.xlsx()
  - 확인하기:
    - file.exists('d_sigungu.xlsx')
    - list.files() # 폴더내 파일 확인

```
> ?write.xlsx # Write a data.frame to an Excel workbook
```

Write a data.frame to an Excel workbook.

**Description**

Write a `data.frame` to an Excel workbook.

**Usage**

```
write.xlsx(x, file, sheetName="Sheet1",
  col.names=TRUE, row.names=TRUE, append=FALSE, showNA=TRUE, pas

write.xlsx2(x, file, sheetName="Sheet1",
  col.names=TRUE, row.names=TRUE, append=FALSE, password=NULL, .
```

```
> write.xlsx(data_sigungu2, # 저장할 객체이름
+            'd_sigungu.xlsx', # 저장할 엑셀 파일 이름
+            sheetName="data") # 엑셀 시트 이름
> file.exists('d_sigungu.xlsx')
[1] TRUE
> list.files()
```

# 연습문제 01

- 다음 중 R에서 rJava 패키지와 연동되어야 작동하는 함수(명령어)를 모두 고르시오.

① read.table
② read.csv
③ write.csv
④ write.xlsx
⑤ read.xlsx
⑥ read_xlsx
⑦ read_xls
⑧ read_excel

# 연습문제 02

- 아래와 같은 폴더내에 있는 csv파일을 불러들여 x라는 객체에 할당하고자 할 때, 사용하게 될 올바른 명령문(함수)를 적으시오.
  - I:₩강의₩수치해석₩3주차₩데이터_아파트매매가격.csv

# 데이터 탐구하기

- 데이터 불러오기

```
> apt <- read.table('데이터_아파트매매가격.csv',
+                   sep=",",  # 구분자 = ","
+                   header = TRUE,  # 첫행을 변수명으로
+                   stringsAsFactors = TRUE) # 명목변수(열)은 요인으로 불러오기
```

- 데이터 확인하기
  - str()
  - head()
  - tail()

```
> str(apt) # 데이터 구조
'data.frame':   13309 obs. of  14 variables:
 $ id            : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price     : int  4800 4500 4000 4000 4000 4000 4(
 $ area_m2       : num  39.8 39.8 39.8 39.8 39.8 39.8 39
 $ floor_no      : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built    : int  1998 1998 1998 1998 1998 1998 19
 $ ym_sale       : int  201811 201811 201812 201812 2018
 $ day_sale      : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban         : Factor w/ 3 levels "동","면","읍": 3 3
```

```
> head(apt) # 첫 행부터 6번째 행까지 데이터 확인
  id apt_price area_m2 floor_no year_built ym_sale day_sale
1  1      4800    39.8        2       1998  201811        6
2  2      4500    39.8        6       1998  201811       13
3  3      4000    39.8        7       1998  201812       10
4  4      4000    39.8        9       1998  201812       10
5  5      4000    39.8        3       1998  201812       10
6  6      4000    39.8        7       1998  201812       10
```

```
> tail(apt) # 맨 마지막행 부터 6번째 행까지 데이터 확인
          id apt_price area_m2 floor_no year_built ym_sale
13304 13304     11300   84.68       15       2002  201907
13305 13305     10700   84.68        3       2002  201907
13306 13306     10700   84.68        7       2002  201907
13307 13307     12800   84.68       14       2002  201908
13308 13308     12500   84.68       14       2002  201908
13309 13309     12300   84.68        2       2002  201908
```

# 데이터 탐구하기

- 데이터 확인하기
  - View() : Invoke a spreadsheet-style data viewer on a matrix-like **R** object.
    - 'V'는 대문자
  - summary()

```
> View(apt) # 창으로 데이터 확인
```

Filter

| | id | apt_price | area_m2 | floor_no | year_built | ym_sale | day_sale | urban | apt_complex |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 1 | 4800 | 39.8000 | 2 | 1998 | 201811 | 6 | 을 | 두진백로 |
| 2 | 2 | 4500 | 39.8000 | 6 | 1998 | 201811 | 13 | 을 | 두진백로 |
| 3 | 3 | 4000 | 39.8000 | 7 | 1998 | 201812 | 10 | 을 | 두진백로 |
| 4 | 4 | 4000 | 39.8000 | 9 | 1998 | 201812 | 10 | 을 | 두진백로 |
| | | | | | | | | | 두진백로 |
| | | | | | | | | | 두진백로 |
| | | | | | | | | | 두진백로 |

```
> summary(apt) # 요약통계
       id          apt_price         area_m2          floor_no      
 Min.   :    1   Min.   :  1250   Min.   : 14.98   Min.   :-1.000  
 1st Qu.: 3328   1st Qu.:  7700   1st Qu.: 58.93   1st Qu.: 4.000  
 Median : 6655   Median : 13500   Median : 60.00   Median : 8.000  
 Mean   : 6655   Mean   : 14553   Mean   : 68.92   Mean   : 8.835  
 3rd Qu.: 9982   3rd Qu.: 19500   3rd Qu.: 84.89   3rd Qu.:12.000  
 Max.   :13309   Max.   :108000   Max.   :244.07   Max.   :48.000  
```

# 데이터 탐구하기

- 데이터 분포 및 요약 통계
  - hist(apt$apt_price) # 아파트 실거래 가격(만원) 히스토 그램
  - ?quantile() # produces quantiles corresponding to the given probabilities
    - quantile(apt$apt_price, probs = seq(0, 1, 0.1)) # 10분위
    - quantile(apt$apt_price, probs = seq(0.9, 1, 0.01)) # 90분위 부터 1% 씩 가격 확인

```
> hist(apt$apt_price) # 아파트 실거래 가격(만원) 히스토 그램
```

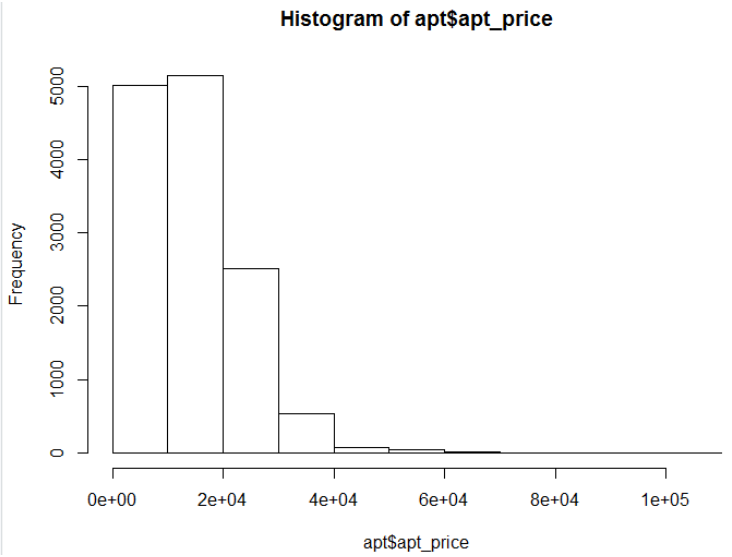


```
> quantile(apt$apt_price, probs = seq(0, 1, 0.1)) # 10분위
    0%    10%    20%    30%    40%    50%    60%    70%    80%    90%   100%
  1250   4700   6800   8500  10900  13500  15370  18000  21800  25500 108000
> quantile(apt$apt_price, probs = seq(0.9, 1, 0.01)) # 90분위 부터 1% 씩 가격 확인
   90%    91%    92%    93%    94%    95%    96%    97%    98%    99%   100%
 25500  26000  27000  28000  29000  30000  31500  33876  36200  39492 108000
```

# 데이터 탐구하기

- 자료의 크기와 길이 확인
  - nrow(apt) # 행의 갯수
  - ncol(apt) # 열의 갯수
  - dim(apt) # 행과 열의 갯수

```
> nrow(apt) # 행의 갯수
[1] 13309
> ncol(apt) # 열의 갯수
[1] 14
> dim(apt) # 행과 열의 갯수
[1] 13309    14
```

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 데이터 접근: 색인([ ]) 또는 키($)로 접근 가능
  - $
    - d$colname: 데이터 프레임 d의 colname에 저장된 데이터
    - d$colname[n]: 데이터 프레임 d의 colname의 n번째 행
  - d[m, n, drop=TRUE]
    - 데이터 프레임 d의 m행 n열 컬럼에 저장된 데이터
    - d[n] : n번째 요소, 숫자 또는 셀의 이름
    - d[-n] : n번째 요소를 제외한 나머지
    - d[start:end] : 벡터의 start부터 end까지의 값을 반환함. 시작과 끝 포함

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 예:

```
> apt[1, 2] # 첫째행과 두번째 열에 있는 값은?
[1] 4800
> apt[13309, -2:-14]# 13309행과 2번째 부터 14번째 열을 제외한 열들에 있는 값은?
[1] 13309
> apt[1:2, 3:5] # 1:2행과 3:5열에 있는 값들은?
  area_m2 floor_no year_built
1    39.8        2       1998
2    39.8        6       1998
> apt$floor_no[3] # apt 객체 중 층수(floor_no) 열에서 3번째 행에 있는 값은?
[1] 7
> apt$floor_no[c(-1:-2, -4:-13309)] # 위와 동일
[1] 7
```

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 이상치 또는 특정 자료 확인
    - which() # Which indices are TRUE?

```
> which(apt$floor_no %in% -1) # -1이 포함된 행 번호 반환
[1] 1882 1883 1886 1889 1891
> apt[c(1882, 1883, 1886, 1889, 1891 ), ]
        id apt_price area_m2 floor_no year_built ym_sale
1882 1882      2500   56.88       -1       1989  201902
1883 1883      5000   56.88       -1       1989  201902
1886 1886      2000   56.88       -1       1989  201905
1889 1889      3500   56.88       -1       1989  201907
1891 1891      2400   38.25       -1       1989  201907
```

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 이상치 또는 특정 자료 확인
    - %in%:
      - i %in% j : i 객체에서 j객체에 포함되어 있는 색인 번호 반환

```
> which(apt$floor_no %in% -1) # -1이 포함된 행 번호 반환
[1] 1882 1883 1886 1889 1891
```

    - 특정 조건에 맞는 자료 확인

```
> i <- which(apt$apt_price > 60000) # 실거래가가 6억 이상인 아파트 색인
> i
[1]  9147  9156 10299 10303 10316 10323 10324 10349 10361
> apt[i, c(2:9, 14)] # 해당 거래 자료 보기
      apt_price area_m2 floor_no year_built ym_sale day_sale urban          apt_complex address_dong
9147      63000 131.941       24       2015  201809       28     동 대원칸타빌3차아파트        주성동
9156      67000 131.941       23       2015  201901       10     동 대원칸타빌3차아파트        주성동
10299     68000 162.626       45       2010  201810       18     동     신영지웰시티 1차         복대동
10303     60800 152.652        6       2010  201811        3     동     신영지웰시티 1차         복대동
10316     97300 196.976       42       2010  201901       13     동     신영지웰시티 1차         복대동
10323    105000 196.976       42       2010  201902       13     동     신영지웰시티 1차         복대동
10324     64000 152.652       24       2010  201902       20     동     신영지웰시티 1차         복대동
10349    108000 196.976       41       2010  201905       25     동     신영지웰시티 1차         복대동
10361     64500 152.652       39       2010  201907       19     동     신영지웰시티 1차         복대동
```

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 특정 조건에 맞는 자료 확인
    - 새로운 변수(열) 생성
      - 평당 가격 변수 생성
        - <-
      - 요약통계
      - 히스토그램

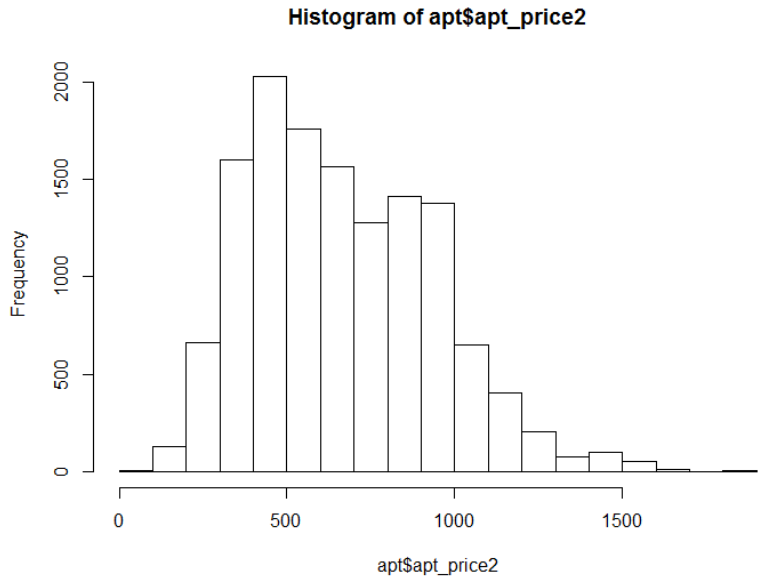


```
> apt$apt_price2 <- apt$apt_price/apt$area_m2*3.3 # 평당 아파트 가격(만원) 변수 생성
> summary(apt$apt_price2)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  85.48  444.44  627.35  666.15  866.05 1825.47
> hist(apt$apt_price2)
```

# 데이터 탐구하기

- 색인(index) 또는 키($)로 데이터 접근하기(찾아보기)
  - 특정 조건에 맞는 자료 확인
    - 아파트 가격이 평당 1600만원 이상 자료 확인
      - which()

```
> j <- which(apt$apt_price2 >= 1600) # 아파트 가격이 평당 1600만원 이상으로 거래된 자료 행 번호
> apt[j, c(2:10, 15)] # 해당 거래 자료 보기
      apt_price  area_m2 floor_no year_built ym_sale day_sale urban          apt_complex
4193      60000 108.4651       29       2018  201905       11     동       청주 센트럴자이 충청북도
9156      67000 131.9410       23       2015  201901       10     동 대원칸타빌3차아파트 충청북도
9998      39800  80.1350       39       2015  201809       27     동 두산위브지웰시티2차 충청북도
10075     39000  80.1350       39       2015  201905       12     동 두산위브지웰시티2차 충청북도
10108     39000  80.1350       34       2015  201907        6     동 두산위브지웰시티2차 충청북도
10112     39400  80.4990       39       2015  201907        8     동 두산위브지웰시티2차 충청북도
10121     39500  80.1350       30       2015  201907       23     동 두산위브지웰시티2차 충청북도
10143     39500  80.4990       31       2015  201908       16     동 두산위브지웰시티2차 충청북도
10316     97300 196.9760       42       2010  201901       13     동     신영지웰시티 1차 충청북도
10323    105000 196.9760       42       2010  201902       13     동     신영지웰시티 1차 충청북도
10349    108000 196.9760       41       2010  201905       25     동     신영지웰시티 1차 충청북도
> apt[j, -11:-14 ] # 해당 거래 자료 보기
        id apt_price  area_m2 floor_no year_built ym_sale day_sale urban          apt_comple
4193  4193     60000 108.4651       29       2018  201905       11     동       청주 센트럴자이
9156  9156     67000 131.9410       23       2015  201901       10     동 대원칸타빌3차아파트
9998  9998     39800  80.1350       39       2015  201809       27     동 두산위브지웰시티2차
10075 10075    39000  80.1350       39       2015  201905       12     동 두산위브지웰시티2차
```

# 데이터 탐구하기

- 문자(명목)변수 탐구하기
  - 요인(factor) 변수 고유값 및 빈도수 테이블 생성과 확인
    - str(apt)
    - unique(apt$urban) # 읍면동 고유값 확인
    - table(apt$urban) # 빈도
    - unique(apt$address_sigungu) # 시군구 고유값 확인
    - table(apt$address_sigungu) # 빈도
    - table(apt[ c('urban', 'address_sigungu')])

```
> unique(apt$urban) # 읍면동 고유값 확인
[1] 읍 면 동
Levels: 동 면 읍
> table(apt$urban) # 빈도

  동   면   읍
8848 1332 3129
>
> unique(apt$address_sigungu) # 시군구 고유값 확인
 [1] 괴산군     단양군     보은군     영동군     옥천군     음성군     제천시     증평군
[13] 청주흥덕구 충주시
Levels: 괴산군 단양군 보은군 영동군 옥천군 음성군 제천시 증평군 진천군 청주상당구 청주서원구
> table(apt$address_sigungu) # 빈도

    괴산군     단양군     보은군     영동군     옥천군     음성군     제천시     증평군
        48        135        102        198        213        897       1264
청주흥덕구     충주시
      2370       1698
>
> table(apt[ c('urban', 'address_sigungu')])
     address_sigungu
urban 괴산군 단양군 보은군 영동군 옥천군 음성군 제천시 증평군 진천군 청주상당구 청주서원구 청주
   동     0      0      0      0      0      0   1215      0      0        1468
   면     1      0      6      8      4    579      0      3    175           7
   읍    47    135     96    190    209    318     49    228    529           0
```

# 데이터 탐구하기

- 순서(서열)형 요인 변수 생성과 확인
  - ordered()
  - str()
  - is.ordered()
  - nlevels()

```
> apt$day_sale <- ordered(apt$day_sale) # 순서형 팩터 생성
> str(apt$day_sale)
 Ord.factor w/ 31 levels "1"<"2"<"3"<"4"<..: 6 13 10 10 10 10 10 10 10 10
> is.ordered(apt$day_sale) # 순서형 팩터 여부 판단
[1] TRUE
> nlevels(apt$day_sale) # 순서형 팩터 라벨 갯수 반환
[1] 31
```

# 데이터 탐구하기

- 하위데이터의 요약 통계: aggregate()
  - aggregate(x, by, FUN, ..., simplify = TRUE, drop = TRUE)
    - i ~ j : j 집단(그룹)별로 i에 대하여 요약 통계르 구하라
      - one ~ one, one ~ many, many ~ one, and many ~ many

```
> aggregate(apt_price ~ urban, FUN=mean, data=apt) # 읍면동(urban)별 평균 실거래 가격
  urban apt_price
1    동  14724.22
2    면  12624.81
3    읍  14888.65
```

# 데이터 탐구하기

- 하위데이터의 요약 통계: aggregate()
  - aggregate(x, by, FUN, ..., simplify = TRUE, drop = TRUE)
    - Manty to one: cbind() 함수 활용
    - Manty to many

```
> ?cbind # Combine R Objects by Columns: 행별 결합은 rbind()
> x <- aggregate(cbind(apt_price, apt_price2)
+           ~ urban, FUN=mean, data=apt) # 읍면동(urban)별 평균 거래 가격과 평당 가격
> x
  urban apt_price apt_price2
1    동  14724.22   674.3314
2    면  12624.81   612.8632
3    읍  14888.65   665.6805
> x2 <- aggregate(cbind(apt_price, apt_price2)
+           ~ address_sigungu + urban, FUN=mean, data=apt) # 시군구별 읍면동(urban)별 평균 거래 가격과 평당 가격
> head(x2)
  address_sigungu urban apt_price apt_price2
1          제천시    동  11466.14    549.6755
2      청주상당구    동  14801.04   656.3173
3      청주서원구    동  15068.47   701.4172
4      청주청원구    동  16971.64   740.2430
5      청주흥덕구    동  18577.32   845.0420
6          충주시    동  10719.81    509.1005
```

# 데이터 탐구하기

- 하위데이터의 요약 통계: aggregate()
  - aggregate(x, by, FUN, ..., simplify = TRUE, drop = TRUE)
    - 색인으로 추출

```
> aggregate(apt[ , 'apt_price'], apt[ , 'urban', drop=FALSE], mean)
  urban        x
1    동 14724.22
2    면 12624.81
3    읍 14888.65
> aggregate(apt[ , c('apt_price', 'apt_price2')], apt[ , 'urban', drop=FALSE], mean, na.rm=TRUE)
  urban apt_price apt_price2
1    동  14724.22   674.3314
2    면  12624.81   612.8632
3    읍  14888.65   665.6805
> aggregate(apt[ , c('apt_price', 'apt_price2')], apt[ , 'ym_sale', drop=FALSE], mean, na.rm=TRUE)
   ym_sale apt_price apt_price2
1   201809  14744.04   676.6967
2   201810  15813.51   708.7854
3   201811  14470.37   662.3380
4   201812  13886.61   660.3361
5   201901  14776.15   658.9688
6   201902  14433.34   653.5126
7   201903  13958.03   636.7984
8   201904  14037.45   639.5075
9   201905  14350.37   653.7078
10  201906  14151.45   665.0134
11  201907  14492.23   666.2532
12  201908  15235.40   706.1628
```

# 데이터 탐구하기

- 하위데이터의 요약 통계: aggregate()
  - aggregate(x, by, FUN, ..., simplify = TRUE, drop = TRUE)
    - 'by' 인수 활용 예

```
> y <- aggregate(apt[ , c(2:5, 15)], # 집계화하고자 하는 데이터 프레임
+                by = list(apt$year_built), # 그룹화할 변수들의 리스트
+                FUN = mean) # 계산하고자 하는 함수( Maximum, minimum, count, standard deviation and sum)
> head(y)
  Group.1 apt_price  area_m2 floor_no year_built apt_price2
1    1977 10016.667 64.15333 1.666667       1977   515.9706
2    1978  8728.571 64.46286 3.142857       1978   452.9652
3    1979  5104.545 48.50227 3.363636       1979   350.0775
4    1980  3705.926 47.60963 2.925926       1980   237.7294
5    1981  4508.919 43.93459 3.243243       1981   342.3330
6    1982  8215.000 64.60550 3.450000       1982   411.6612
```

# 데이터 탐구하기

- 행과 열의 집단별 요약통계: lapply, sapply, tapply
  - apply()  # Apply Functions Over Array Margins: apply(X, MARGIN, FUN, ...)
  - lapply() # Apply a Function over a List or Vector
  - sapply() # a user-friendly version and wrapper of lapply by default returning a vector, matrix, or others
  - tapply() # Apply a Function Over a Ragged Array

```
> ?tapply # Apply a Function Over a Ragged Array
> tapply(apt$apt_price, apt$urban, mean) # 읍면동별 평균 거래 가격
      동       면       읍
14724.22 12624.81 14888.65
> tapply(apt[ , 'apt_price'], apt[ , 'urban'], mean) # 읍면동별 평균 거래 가격
      동       면       읍
14724.22 12624.81 14888.65
```

# 연습문제 03

- 전용면적(area_m2)이 30m2이하이면서  아파트 가격(apt_price)이 2000만원 이하로 거래된 자료 행 번호를 which()로 추출하였을 때, 총 몇개의 아파트 거래건수가 있는 지 적으시오.
  - 사용할 데이터(객체)는 다음과 같음
    - apt <- read.table('데이터_아파트매매가격.csv', sep=",", header = TRUE, stringsAsFactors = TRUE)

# 연습문제 03

- 전용면적(area_m2)이 30m2이하이면서  아파트 가격(apt_price)이 2000만원 이하로 거래된 자료 행 번호를 which()로 추출하였을 때, 총 몇개의 아파트 거래건수가 있는 지 적으시오.
  - 사용할 데이터(객체)는 다음과 같음
    - apt <- read.table('데이터_아파트매매가격.csv', sep=",", header = TRUE, stringsAsFactors = TRUE)

# 연습문제 04

- 시군구(address_sigungu)별 평균 아파트 가격을 알기 위하여 tapply()로 사용하여 구하시오. 이 때 평균 아파트 거래가격(apt_price)이 가장 높은 시군구를 적으시오.

# 데이터 정렬, 병합, 변환, 추출하기

- 대용량 데이터를 다룰 때, 이들 데이터의 정렬, 병합, 추출, 재구조화는 분석 단계 이전에서 중요한 역할을 함
  - 데이터 구조의 병합(merge), 정렬(sort), 재구조화(reshape)의 실습을 하는 것은 중요
- 데이터 정렬:
  - sort() : 데이터 프레임에는 적용 안됨(벡터만 가능)
  - order()
    - 데이터의 특정 변수들의 값들을 정렬(오름차순 및 내림차순)하여 데이터 탐구 및 추출을 용이하기 하는 절차적 변환
    - 사용법: order(…, na.last = TRUE, decreasing = FALSE, method = c(“auto”, “shell”, “radix”))
      - 정렬 방법: 오름차순 정렬과 내림차순 정렬

# 데이터 정렬, 병합, 변환, 추출하기

- 정렬: sort()
  - 벡터만 가능

```
> x <- apt$apt_price
> summary(x)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1250    7700   13500   14553   19500  108000
> head(sort(x)) # 올림차순 정렬
[1] 1250 1250 1250 1250 1300 1300
> head(sort(x, decreasing=TRUE)) # 내림차순 정렬
[1] 108000 105000  97300  68000  67000  64500
```

- 정렬: order()
  - apt[order(apt$apt_price) , 1: 3]

# 데이터 정렬, 병합, 변환, 추출하기

- 정렬: order()

```
> ?order
> x <- apt[order(apt$apt_price) # apt_price에 대하여 오름차순 정렬
+          , 1:3] # 1:3 열만 추출
> head(x)
       id apt_price area_m2
511   511      1250  39.950
512   512      1250  39.950
513   513      1250  39.950
514   514      1250  39.950
189   189      1300  50.185
2637 2637      1300  42.540
> x <- apt[order(-apt$apt_price) # id에 대하여 내림차순 정렬
+          , 1:3] # 1:3 열만 추출
> head(x)
         id apt_price area_m2
10349 10349    108000 196.976
10323 10323    105000 196.976
10316 10316     97300 196.976
10299 10299     68000 162.626
9156   9156     67000 131.941
10361 10361     64500 152.652
> x <- apt[order(-apt$area_m2, -apt$apt_price) #  area_m2와  apt_price에 대하여 내림차순 정렬
+          , 1:5] #  첫번째 열부터 다섯번째 열까지만
> head(x)
         id apt_price  area_m2 floor_no year_built
12280 12280     31000 244.0710       18       2007
10745 10745     46700 219.0313       14       2005
11094 11094     25600 203.1600        6       1995
10349 10349    108000 196.9760       41       2010
10323 10323    105000 196.9760       42       2010
10316 10316     97300 196.9760       42       2010
```

# 데이터 정렬, 병합, 변환, 추출하기

- 데이터 구조 변환: reshape
  - **from Wide to Long**
  - **Data from long to wide**

**Wide** ⟷ **Long**

| id | gender | race | trt | day1 | day2 | day3 |
|---|---|---|---|---|---|---|
| 1 | F | 0 | 0 | 19.81310 | 18.05777 | 14.84996 |
| 2 | M | 0 | 0 | 17.91846 | 18.75825 | 15.30547 |
| 3 | M | 0 | 0 | 17.22526 | 19.79218 | 15.10622 |

| id | gender | race | trt | day | amt |
|---|---|---|---|---|---|
| 1 | F | 0 | 0 | day1 | 19.81310 |
| 1 | F | 0 | 0 | day2 | 18.05777 |
| 1 | F | 0 | 0 | day3 | 14.84996 |
| 2 | M | 0 | 0 | day1 | 17.91846 |
| 2 | M | 0 | 0 | day2 | 18.75825 |
| 2 | M | 0 | 0 | day3 | 15.30547 |
| 3 | M | 0 | 0 | day1 | 17.22526 |
| 3 | M | 0 | 0 | day2 | 19.79218 |
| 3 | M | 0 | 0 | day3 | 15.10622 |

# 데이터 정렬, 병합, 변환, 추출하기

- 데이터 구조 변환: reshape()
  - Wide → Long
  - Long → Wide

```
reshape(wide, direction = "long")
reshape(wide, idvar = "Subject", varying = list(2:12),
        v.names = "conc", direction = "long")
```

```
reshape(df, timevar = "visit", idvar = "id", direction = "wide")
```

  - 인수:
    - direction = “wide” 또는 “long”
    - idvar = long 유형에서 동일 집단의 다수 행(레코드)을 가진 변수(들)
    - varying = 하나의 새로운 변수로 통합할 변수들 목록
    - v.names = long 유형으로 변환하였을(할) 때의 새로운 변수명
    - times = 숫자대신에 통합되어질 고유 변수명 사용
    - timevar = 새로이 만들어진 변수인 time의 이름 부여

# 데이터 정렬, 병합, 변환, 추출하기

- 데이터 구조 변환: reshape()
  - 예: wide to long # 매매와 전세 가격을 하나의 열로 재구조화
    - Long <- reshape(d, varying=c("apt_sale_price", "apt_junse_price"), v.names ="price", timevar = "type", times=c("apt_sale_price", "apt_junse_price"), direction = "long")
    - str(Long)
    - head(Long)
    - View(Long)

```
> Long <- reshape(d, # 재구조화하고자 하는 데이터
+              varying=c("apt_sale_price", "apt_junse_price"), # 하나의 변수로 통합할
+               v.names="price", # 새로운 변수명
+               timevar = "type", # 통합되어 만들어진 새로운 변수 이름 부여
+               times=c("apt_sale_price", "apt_junse_price"), # 숫자 대신 새로운 변수(
+               direction = "long") # 재구조화 방향
> str(Long)
'data.frame':   522 obs. of  3 variables:
 $ id   : num  1 2 3 4 5 6 7 8 9 10 ...
 $ type : chr  "apt_sale_price" "apt_sale_price" "apt_sale_price" "apt_sale_price"
 $ price: num  102 104 105 105 104 ...
 - attr(*, "reshapeLong")=List of 4
  ..$ varying:List of 1
  .. ..$ price: chr  "apt_sale_price" "apt_junse_price"
  .. ..- attr(*, "v.names")= chr "price"
  .. ..- attr(*, "times")= chr  "apt_sale_price" "apt_junse_price"
  ..$ v.names: chr "price"
  ..$ idvar  : chr "id"
  ..$ timevar: chr "type"
> head(Long)
                    id           type price
1.apt_sale_price  1 apt_sale_price 102.4
2.apt_sale_price  2 apt_sale_price 103.6
3.apt_sale_price  3 apt_sale_price 105.0
4.apt_sale_price  4 apt_sale_price 105.2
5.apt_sale_price  5 apt_sale_price 103.9
6.apt_sale_price  6 apt_sale_price 102.1
```

# 데이터 정렬, 병합, 변환, 추출하기

- 부분 데이터 또는 특정 조건에 맞는 데이터 추출: subset()
  - 벡터, 행렬, 데이터 프레임에서 부분 데이터 또는 특정 조건을 충족하는 하위데이터 추출할 때 유용하게 사용되는 함수(명령문)
  - 하위(부분) 데이터 추출

```
> sub_d <- subset(apt, # 추출할 데이터(객체)
+                 select = id: urban) # id열부터 urban 열까지만 데이터 선택
> str(sub_d)
'data.frame':   13309 obs. of  8 variables:
 $ id        : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price : int  4800 4500 4000 4000 4000 4000 4000 4000 4000 4800 ..
 $ area_m2   : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 ..
 $ floor_no  : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built: int  1998 1998 1998 1998 1998 1998 1998 1998 1998 1998 ..
 $ ym_sale   : int  201811 201811 201812 201812 201812 201812 201812 201
 $ day_sale  : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban     : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3 3 3 3 3 ...
```

# 데이터 정렬, 병합, 변환, 추출하기

- 부분 데이터 또는 특정 조건에 맞는 데이터 추출: subset()
  - 조건 및 하위(부분) 데이터 추출

```
> d2 <- subset(apt,  # 추출할 데이터(객체)
+              urban=="동", # 조건: urban이 "동"인 데이터 # 추출할 열(변수) 목록
+              select = c("urban", "apt_price", "area_m2"),)
> str(d2)
'data.frame':   8848 obs. of  3 variables:
 $ urban    : Factor w/ 3 levels "동","면","읍": 1 1 1 1 1 1 1 1 1 1 ...
 $ apt_price: int  22500 22000 21500 22500 21300 21500 21500 15500 18900 2:
 $ area_m2  : num  84.4 84.4 84.4 84.4 84.4 ...
> table(d2$urban) # 빈도

  동   면   읍
8848    0    0
> a <- subset(apt,
+              floor_no >20 & ym_sale <= 201812, # 층수가 20층 초과이면서 거래년월이 201812보다 이하
+              select = c(-day_sale: -address_dong)) # day_sale 열부터 address_dong열 제외하고 선택
> str(a)
'data.frame':   309 obs. of  6 variables:
 $ id        : int  1244 1246 1297 1299 2318 2319 2320 2322 4183 5189 ...
 $ apt_price : int  19800 16600 15400 16000 24200 17800 16900 17000 31710 26000 ...
 $ area_m2   : num  84.5 74.4 59.9 59.9 78.4 ...
 $ floor_no  : int  22 23 21 21 26 32 34 21 22 23 ...
 $ year_built: int  2014 2014 2014 2014 2017 2017 2017 2017 2018 2013 ...
 $ ym_sale   : int  201810 201811 201809 201810 201809 201809 201809 201811 201812 201810 ...
```

# 데이터 정렬, 병합, 변환, 추출하기

- 좌우 데이터(프레임) 병합: merge()
  - 사용법: merge(x, y, by = intersect(names(x), names(y)), by.x = by, by.y = by, all = FALSE, all.x = all, all.y = all, sort = TRUE, suffixes = c(".x",".y"), incomparables = NULL, ...)

```
> str(apt) # 아파트 거래 자료의 시도, 시군구
'data.frame':   13309 obs. of  14 variables:
 $ id             : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price      : int  4800 4500 4000 4000 4000 4000 4000 4000
 $ area_m2        : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8
 $ floor_no       : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built     : int  1998 1998 1998 1998 1998 1998 1998 1998
 $ ym_sale        : int  201811 201811 201812 201812 201812 20181
 $ day_sale       : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban          : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3
 $ apt_complex    : Factor w/ 802 levels "(1028-0)","(142-1)",...:
 $ address        : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사
 $ address_bunji  : Factor w/ 873 levels "1","1-1","1-16",...: 216
 $ address_sido   : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1
 $ address_sigungu: Factor w/ 14 levels "괴산군","단양군",..: 1 1 1
 $ address_dong   : Factor w/ 107 levels "가경동","감곡면",..: 9 9
```

```
> str(data_sigungu) # 시군구 통계자료의 시도, 시군구
'data.frame':   261 obs. of  16 variables:
 $ id                 : num  1 2 3 4 5 6 7 8 9 10 ...
 $ sido               : Factor w/ 17 levels "강원도","경기도",..: 9 9 9 9 9 9 9 9 9 9
 $ sigungu            : Factor w/ 236 levels "가평군","강남구",..: 190 191 161 110 2
 $ area               : num  23.91 9.96 21.87 16.86 17.06 ...
 $ pop_density        : num  6387 12574 10529 17750 20935 ...
 $ pop_tot            : num  154770 125709 229161 304808 357703 ...
 $ pop_male           : num  75967 62253 110878 150368 174414 ...
 $ pop_female         : num  78803 63456 118283 154440 183289 ...
 $ age_average        : Factor w/ 132 levels "-","35.9","36.2",..: 48 54 48 40 36
 $ r_aged             : num  17.1 17.1 16 13.6 12.5 ...
 $ pop_net_move       : num  -204 143 -89 57 -608 -469 -429 -716 -521 -308 ...
 $ housing            : num  45729 40177 71680 87830 85638 ...
 $ apt_sale_price     : num  102 104 105 105 104 ...
 $ apt_junse_price    : num  102 101 100 100 102 ...
 $ car                : num  0.33 0.41 0.34 0.34 0.28 0.28 0.28 0.27 0.24 0.29 ...
 $ accident_per_1000car: num  18.82 18.72 14.64 8.54 8.72 ...
```

# 데이터 정렬, 병합, 변환, 추출하기

- 좌우 데이터(프레임) 병합: merge()
  - 아파트 거래자료(x)와 시군구 통계 자료(y) 좌우 병합
    - 병합 기준 id
    - 매칭된 두 데이터만 병합

```
> m1 <- merge(apt, data_sigungu, # merge할 두 데이터 프레임(x, y)
+             by.x = c("address_sido", "address_sigungu"), # x데이터의 병합 기준 id
+             by.y = c("sido", "sigungu")) # y 객체의 병합 기준 id
> str(m1)
'data.frame':   5490 obs. of  28 variables:
 $ address_sido        : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu     : Factor w/ 14 levels "괴산군","단양군",..: 1 1 1 1 1 1 1 1 1 1 .
 $ id.x                : int  1 7 8 9 10 11 12 13 14 2 ...
 $ apt_price           : int  4800 4000 4000 4000 4800 4000 4000 4000 6300 4500 ...
 $ area_m2             : num  39.8 39.8 39.8 39.8 39.8 ...
 $ floor_no            : int  2 5 9 8 5 10 1 1 5 6 ...
 $ year_built          : int  1998 1998 1998 1998 1998 1998 1998 1998 1985 1998 ...
 $ ym_sale             : int  201811 201812 201812 201812 201901 201901 201901 201901
 $ day_sale            : int  6 10 10 10 10 11 22 22 18 13 ...
 $ urban               : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3 3 3 3 3 ...
 $ apt_complex         : Factor w/ 802 levels "(1028-0)","(142-1)",..: 167 167 167 167
 $ address             : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리",..: 1 1 1 1 1
 $ address_bunji       : Factor w/ 873 levels "1","1-1","1-16",..: 216 216 216 216 216
 $ address_dong        : Factor w/ 107 levels "가경동","감곡면",..: 9 9 9 9 9 9 9 9 9 9
 $ id.y                : num  153 153 153 153 153 153 153 153 153 153 ...
 $ area                : num  407 407 407 407 407 ...
 $ pop_density         : num  172 172 172 172 172 ...
 $ pop_tot             : num  73677 73677 73677 73677 73677 ...
 $ pop_male            : num  38314 38314 38314 38314 38314 ...
 $ pop_female          : num  35363 35363 35363 35363 35363 ...
 $ age_average         : Factor w/ 132 levels "-","35.9","36.2",..: 109 109 109 109 10
 $ r_aged              : num  31.1 31.1 31.1 31.1 31.1 ...
 $ pop_net_move        : num  391 391 391 391 391 391 391 391 391 391 ...
 $ housing             : num  16380 16380 16380 16380 16380 ...
 $ apt_sale_price      : num  NA NA NA NA NA NA NA NA NA NA ...
 $ apt_junse_price     : num  NA NA NA NA NA NA NA NA NA NA ...
 $ car                 : num  0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 ...
 $ accident_per_1000car: num  9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 ...
> View(m1)
```

# 데이터 정렬, 병합, 변환, 추출하기

- 좌우 데이터(프레임) 병합: merge()
  - 아파트 거래자료(x)와 시군구 통계 자료(y) 좌우 병합
    - 병합 기준 id
    - all.x = TRUE
      - 매칭되지 않아도 x 객체 모두 남겨둠
    - all.y = TRUE
      - 매칭되지 않아도 y 객체 모두 남겨둠

```
> m2 <- merge(apt, data_sigungu,
+             by.x = c("address_sido", "address_sigungu"),
+             by.y = c("sido", "sigungu"),
+             all.x=TRUE) # x데이터 프레임은 매칭 되지 않아도 모두 남겨둠
> str(m2)
'data.frame':   13309 obs. of  28 variables:
 $ address_sido        : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu     : Factor w/ 14 levels "괴산군","단양군",..: 1 1 1 1 1 1 1 1 1
 $ id.x                : int  1 7 8 9 10 11 12 13 14 2 ...
 $ apt_price           : int  4800 4000 4000 4000 4800 4000 4000 4000 6300 4500 ...
 $ area_m2             : num  39.8 39.8 39.8 39.8 39.8 ...
 $ floor_no            : int  2 5 9 8 5 10 1 1 5 6 ...
 $ year_built          : int  1998 1998 1998 1998 1998 1998 1998 1998 1985 1998 ...
 $ ym_sale             : int  201811 201812 201812 201812 201901 201901 201901 2019
 $ day_sale            : int  6 10 10 10 10 11 22 22 18 13 ...
 $ urban               : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3 3 3 3 3 ...
 $ apt_complex         : Factor w/ 802 levels "(1028-0)","(142-1)",..: 167 167 167
 $ address             : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리",..: 1 1 1
 $ address_bunji       : Factor w/ 873 levels "1","1-1","1-16",..: 216 216 216 216
 $ address_dong        : Factor w/ 107 levels "가경동","감곡면",..: 9 9 9 9 9 9 9 9 9
 $ id.y                : num  153 153 153 153 153 153 153 153 153 153 ...
 $ area                : num  407 407 407 407 407 ...
 $ pop_density         : num  172 172 172 172 172 ...
 $ pop_tot             : num  73677 73677 73677 73677 73677 ...
 $ pop_male            : num  38314 38314 38314 38314 38314 ...
 $ pop_female          : num  35363 35363 35363 35363 35363 ...
 $ age_average         : Factor w/ 132 levels "-","35.9","36.2",..: 109 109 109 109
 $ r_aged              : num  31.1 31.1 31.1 31.1 31.1 ...
 $ pop_net_move        : num  391 391 391 391 391 391 391 391 391 391 ...
 $ housing             : num  16380 16380 16380 16380 16380 ...
 $ apt_sale_price      : num  NA NA NA NA NA NA NA NA NA NA ...
 $ apt_junse_price     : num  NA NA NA NA NA NA NA NA NA NA ...
 $ car                 : num  0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 0.57 ...
 $ accident_per_1000car: num  9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 9.49 ...
> View(m2)
```

# 데이터 정렬, 병합, 변환, 추출하기

- 상하 데이터(프레임) 병합(붙이기): rbind()
  - Combine R Objects by Rows
    - 데이터 구조가 동일할 때 주로 사용
      - 데이터 구조가 다를 경우
        - 일치하는 데이터만 추출하여 실행
    - 예: 아파트 실거래가 자료
      - 충청북도 자료(x)
      - 충청남도, 세종시, 대전시 자료(y)
      - rbind(x, y)

```
> apt_cb <- apt # 충청북도 아파트 거래 사표
> str(apt_cb)
'data.frame':   13309 obs. of  14 variables:
 $ id              : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price       : int  4800 4500 4000 4000 4000 4000 4000 4000 4000 4800 ...
 $ area_m2         : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 ...
 $ floor_no        : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built      : int  1998 1998 1998 1998 1998 1998 1998 1998 1998 1998 ...
 $ ym_sale         : int  201811 201811 201812 201812 201812 201812 201812 2018
 $ day_sale        : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban           : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3 3 3 3 3 ...
 $ apt_complex     : Factor w/ 802 levels "(1028-0)","(142-1)",..: 167 167 167
 $ address         : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리",..: 1 1 1
 $ address_bunji   : Factor w/ 873 levels "1","1-1","1-16",..: 216 216 216 216
 $ address_sido    : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu: Factor w/ 14 levels "괴산군","단양군",..: 1 1 1 1 1 1 1 1 1
 $ address_dong    : Factor w/ 107 levels "가경동","감곡면",..: 9 9 9 9 9 9 9 9 9
```

```
> apt_cn <- read.table('데이터_아파트(매매)_실거래가_충남대전세종.csv',  # 붙이고자 하는 데이터 파일명
+                      sep=",",  # 구분자 = ","
+                      header = TRUE,  # 첫행을 변수명으로
+                      stringsAsFactors = TRUE) # 명목변수(열)은 요인으로 불러오기
> str(apt_cn)
'data.frame':   44109 obs. of  13 variables:
 $ id              : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price       : int  14700 17000 15900 15500 16700 16900 16200 11000 17950 16000 ...
 $ area_m2         : num  76 85 76 85 85 ...
 $ floor_no        : int  2 11 7 10 3 9 8 1 6 5 ...
 $ year_built      : int  2002 2002 2002 2002 2002 2002 2002 2002 2002 2002 ...
 $ ym_sale         : int  201809 201809 201810 201810 201810 201811 201811 201812 201901 2019
 $ day_sale        : int  19 19 6 8 10 13 20 4 31 9 ...
 $ urban           : Factor w/ 3 levels "동","면","읍": 1 1 1 1 1 1 1 1 1 1 ...
 $ apt_complex     : Factor w/ 1729 levels "(296-1)","(335-118)",..: 110 110 110 110 110 110
 $ address_bunji   : Factor w/ 1625 levels "1","1-1","1-1113",..: 1352 1352 1352 1352 1352 13
 $ address_sido    : Factor w/ 3 levels "대전광역시","세종특별자치시",..: 3 3 3 3 3 3 3 3 3 3 ...
 $ address_sigungu: Factor w/ 43 levels "계룡시","고운동",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ address_dong    : Factor w/ 247 levels "","가수원동",..: 31 31 31 31 31 31 31 31 31 31 ...
```

# 데이터 정렬, 병합, 변환, 추출하기

- 상하 데이터(프레임) 병합(붙이기): rbind()
  - Combine R Objects by Rows
    - 아파트 실거래가 자료
      - 충청북도 자료(apt_cb2)
        - 일치하지 않은 열 제외한 데이터 셋 추출
      - 충청남도, 세종시, 대전시 자료(apt_cn)
      - rbind(apt_cb2, apt_cn)

```
> apt_cb2 <- subset(apt_cb, select = -address) # address 열만 제외한 데이터 셋 추출 후 할당
> apt_cncb <- rbind(apt_cb2, apt_cn)
> str(apt_cncb)
'data.frame':   57418 obs. of  13 variables:
 $ id             : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price      : int  4800 4500 4000 4000 4000 4000 4000 4000 4000 4800 ...
 $ area_m2        : num  39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 39.8 ...
 $ floor_no       : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built     : int  1998 1998 1998 1998 1998 1998 1998 1998 1998 1998 ...
 $ ym_sale        : int  201811 201811 201812 201812 201812 201812 201812 201812 201812 201812
 $ day_sale       : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban          : Factor w/ 3 levels "동","면","읍": 3 3 3 3 3 3 3 3 3 3 ...
 $ apt_complex    : Factor w/ 2436 levels "(1028-0)","(142-1)",..: 167 167 167 167 167 1
 $ address_bunji  : Factor w/ 2270 levels "1","1-1","1-16",..: 216 216 216 216 216 216 2
 $ address_sido   : Factor w/ 4 levels "충청북도","대전광역시",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu: Factor w/ 57 levels "괴산군","단양군",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ address_dong   : Factor w/ 348 levels "가경동","감곡면",..: 9 9 9 9 9 9 9 9 9 9 ...
```

# 데이터 정렬, 병합, 변환, 추출하기

- 알아두면 유용한 함수들: (….) with, attach, detach
  - (….)
    - 문장 시작(“(“)과 끝(“)”)의 괄호는 할당 결과를 바로 실행하여 보여 줌
    - (…)의 있고 없음의 차이
      - k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 )
      - (k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 ))

```
> k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 )
> k
 [1]   473   972   973   976   983   987   988   989  2907
> (k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 ))
 [1]   473   972   973   976   983   987   988   989  2907
```

# 데이터 정렬, 병합, 변환, 추출하기

- 알아두면 유용한 함수들: (....) with, attach, detach
  - (....)
    - 문장 시작("(")과 끝(")")의 괄호는 할당 결과를 바로 실행하여 보여 줌
    - (...)의 있고 없음의 차이
      - k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 )
      - (k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 ))
  - with()
  - attach()
  - detach()

```
> k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 )
> k
 [1]   473   972   973   976   983   987   988   989  2907
> (k <- which(apt$apt_price <= 2000 & apt$area_m2 <=30 ))
 [1]   473   972   973   976   983   987   988   989  2907
```

# 데이터 정렬, 병합, 변환, 추출하기

- 알아두면 유용한 함수들: (….) with, attach, detach
  - with()
    - with(data, expression, …..)
      - with 함수 내(“( )”)의 키($) 사용을 간결하게 하기 위한 함수
    - With 함수가 있고 없음의 차이 확인
      - 데이터(객체) 명 한번만 사용하고, $ 사용 불필요
      - with()로 더욱 간편하게 접근함. 그러나 해당 명령에서만 유효

```
> ?with()
> a1 <- apt_cncb$apt_price[apt_cncb$floor_no >20 & apt_cncb$area_m2 <60]
> a2 <- with(apt_cncb, apt_price[floor_no >20 & area_m2 <60]) # with()로 더욱
```

# 기타 유용한 함수들: (….) with, attach, detach

- 기타 알아두면 유용한 함수들: (….) with, attach, detach
  - attach(): Attach Set of R Objects to Search Path
    - 데이터(객체)를 attach()로 설정하면, "객체$"를 사용하지 않고 바로 접근(사용) 가능
      - with()함수는 해당 함수 내에서만 작동
      - attach()함수는 detach()함수를 적용하기 이전에는 계속 사용 가능
        - with()함수 보다 편리하게 데이터 내 접근하여 사용

```
> ?attach # Attach Set of R Objects to Search Path
> summary(mtcars$mpg) # 내장 데이터에 있는 mpg파일 요약통계
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  10.40   15.43   19.20   20.09   22.80   33.90
> attach(mtcars) # "mtcars" 객체(데이터) 바로 접근 적용
> summary(mpg) # "mtcars$" 없이 데이터 접근
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  10.40   15.43   19.20   20.09   22.80   33.90
> detach() # 해제
> summary(mpg) # 해제 후에는 접근 안됨
Error in summary(mpg) : object 'mpg' not found
```

# 연습문제 05

- 아파트 전용면적(area_m2)이 100m2 이하이면서, 그 가격(apt_price)이 2억이하로 거래된 자료만 추출하되, apt_complex 열 제외하고 선택하였을 때, 이 때 관측치(행)의 갯수와 열(변수)의 갯수를 적으시오. 이 때 사용할 함수는 subset()임
  - 사용할 데이터(객체)는 다음과 같음
    - apt <- read.table('데이터_아파트매매가격.csv', sep=",", header = TRUE, stringsAsFactors = TRUE)

# 연습문제 06

- 데이터(mtcars)의 hp 변수의 요약통계를 살펴보고자 한다. 올바르게 사용한 명령문을 모두 고르시오.

① summary(hp)

② summary(mtcars$ hp)

③ with(mtcars, hp)

④ attach(mtcars) ; summary(mtcars$ hp)

⑤ attach(mtcars) ; summary(hp)

⑥ detach(mtcars) ; summary(hp)

# dplyr 패키지 소개

- 기존 데이터 가공 방법들 검토
  - 데이터프레임의 일부를 추출하기 위한 subset() 함수와 [ 과 $ 운영자의 이용 가능
  - 그러나 이들 함수와 운영자들은 추출, 재정렬, 집계화 등의 작업에서의 쉽지 않음
    - tedious operations
    - not very intuitive
- The dplyr package
  - designed to mitigate a lot of these problems and to provide a highly optimized set of routines specifically for dealing with data frames

# dplyr 패키지 소개

- The dplyr Package
  - Not provide any “new” functionality to R per se
  - could already be done with base R
  - but it greatly simplifies existing functionality in R.

```
# install dplyr package
install.packages("tidyverse")
install.packages("dplyr")

library(dplyr)
?dplyr
```

dplyr-package {dplyr} R Documentation

## dplyr: a grammar of data manipulation

### Description

dplyr provides a flexible grammar of data manipulation. It's the next iteration of plyr, focused on tools for working with data frames (hence the *d* in the name).

# dplyr 패키지 소개

- dplyr package의 장점
  - a flexible grammar of data manipulation
  - focused on tools for working with data frames (hence the *d* in the name).
  - three main goals
    - Identify the most important data manipulation verbs and make them easy to use from R.
      - select(), filter(), arrange(), rename(), mutate(), summarise()/summarize(), %>%
    - Provide blazing fast performance for in-memory data by writing key pieces in C++ (using Rcpp)
    - Use the same interface to work with data no matter where it's stored, whether in a data frame, a data table or database
      - relational databases that allow you to operate on very very large data frames

# dplyr 패키지 소개

- dplyr package의 특징
  - Hadley Wickham가 작성한 데이터 처리에 특화된 R 패키지
    - plyr도 편리하긴 했지만 모든 함수가 R로 작성되어서 처리 속도가 느림
    - dplyr은 C++로 작성되어 불필요한 함수를 불러오지 않기 때문에 처리 속도 빠름
  - 다음 형식의 데이터 사용가능
    - data.table : data.table 패키지와 사용
    - 각종 데이터베이스 : 현재 MySQL, PostgreSQL, SQLite, BigQuery를 지원
    - 데이터 큐브 : dplyr 패키지 내부에 실험적으로 내장됨

# dplyr 패키지 소개

- dplyr package 함수와 유사 R 함수 비교

| 함수명 | 내용 | 유사함수 |
|---|---|---|
| filter() | 지정한 조건식에 맞는 데이터 추출 | subset() |
| select() | 열의 추출 | data[, c("Year", "Month")] |
| mutate() | 열 추가 | transform() |
| arrange() | 정렬 | order(), sort() |
| summarise() | 집계 | aggregate() |

출처: https://wsyang.com/2014/02/introduction-to-dplyr/

- group_by() 함수
  - 집단별로 다양한 집계를 추가로 활용 가능

# dplyr 패키지 소개

- The key **"verbs"** provided by the dplyr package
  - select()
    - return a subset of the columns of a data frame, using a flexible notation
  - filter()
    - extract a subset of rows from a data frame based on logical conditions
  - arrange()
    - reorder rows of a data frame
  - rename()
    - rename variables in a data frame
  - mutate(), transmute()
    - add new variables/columns or transform existing variables
  - summarise() 또는 summarize()
    - generate summary statistics of different variables in the data frame, possibly within strata
  - %>%
    - the "pipe" operator is used to connect multiple verb actions together into a pipeline
    - 파이프(pipe) 연산자를 사용해서 dplyr 동사를 순열로 조합하여 연결
  - transform(), recode()
  - distinct(), between(), row_number(), row_number(), n() 등

# dplyr 패키지 소개

- 공통으로 적용되는 dplyr 함수 특징들
  - 첫번째 인수는 데이터 프레임(data frame)
  - 이후의 일련의 인수들은 해당 데이터로 해야 할 작업 설정과 키($) 없이 열(변수)에 접근할 수 있음
  - 함수 실행의 반환 결과는 새로운 데이터 프레임
  - 데이터 프레임은 한 줄당 한 개의 관측치로 구성되어야 함
  - Data frames must be properly formatted and annotated for this to all be useful.
    - In particular, the data must be tidy.
    - In short, there should be one observation per row, and each column should represent a feature or characteristic of that observation.

# 추출하기: select()

- 열(변수)별로 지정한 열(변수)들을 선택하는 함수
- 유용한 기능들
  - X:y : x열 부터 y열까지만 선택하여 추출
  - c(x, y:z) : x와 y열부터 z열만 선택하여 추출
  - -x : x열만 제외하고 모두 선택
  - -x : -y : x열부터 y열까지 제외하고 모두 선택
  - select() 에서만 사용되는 특별 기능들
    - starts_with(), ends_with(), contains()
    - matches()
    - num_range()
    - one_of()
    - everything()
    - group_cols()

# dplyr 패키지를 활용한 데이터 마이닝

## 추출하기: select()

- 실습

```
> sub_apt <- select(apt, # 추출할 객체명
+                   floor_no, year_built, ym_sale) # 추출할 열 이름(들)
> head(sub_apt)
  floor_no year_built ym_sale
1        2       1998  201811
2        6       1998  201811
3        7       1998  201812
4        9       1998  201812
5        3       1998  201812
6        7       1998  201812
> sub_apt <- select(apt,  # 추출할 객체명
+                   apt_price:urban) # apt_price열부터 urban열까지 선택
> head(sub_apt)
  apt_price area_m2 floor_no year_built ym_sale day_sale urban
1      4800    39.8        2       1998  201811        6     읍
2      4500    39.8        6       1998  201811       13     읍
3      4000    39.8        7       1998  201812       10     읍
4      4000    39.8        9       1998  201812       10     읍
5      4000    39.8        3       1998  201812       10     읍
6      4000    39.8        7       1998  201812       10     읍
```

```
> sub_apt <- select(apt,
+         -(apt_price:urban)) # apt_price열부터 urban열까지 제외하고 모두 선택
> head(sub_apt)
  id apt_complex                          address address_bunji address_sido address_s
1  1     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
2  2     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
3  3     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
4  4     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
5  5     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
6  6     두진백로 충청북도 괴산군 괴산읍 대사리         177-1     충청북도           괴산군
> sub_apt <- select(apt,
+         ends_with("e")) # e로 끝나는 이름을 가진 열들만 선택
> str(sub_apt)
'data.frame':   13309 obs. of  3 variables:
 $ apt_price: int  4800 4500 4000 4000 4000 4000 4000 4000 4000 4800 ...
 $ ym_sale  : int  201811 201811 201812 201812 201812 201812 201812 201812 201812 2
 $ day_sale : int  6 13 10 10 10 10 10 10 10 10 ...
> sub_apt <- select(apt,
+                   starts_with("address")) # address로 시작하는 이름을가진 열들만 선택
> str(sub_apt)
'data.frame':   13309 obs. of  5 variables:
 $ address        : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리",..: 1 1 1 1 1
 $ address_bunji  : Factor w/ 873 levels "1","1-1","1-16",..: 216 216 216 216 216 2
 $ address_sido   : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu: Factor w/ 14 levels "괴산군","단양군",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ address_dong   : Factor w/ 107 levels "가경동","감곡면",..: 9 9 9 9 9 9 9 9 9 9 ..
```

# 특정 조건에 맞는 데이터 추출하기: filter()

- Return rows with matching conditions
  - choose rows/cases where conditions are true.
  - similar to the existing subset() function in R but is quite a bit faster
  - **Useful filter functions**
    - ==, >, >= etc
    - &, |, !, xor()
    - is.na()
    - between(), near()

# 특정 조건에 맞는 데이터 추출하기: filter()

- 실습

```
> ?filter # Return rows with matching conditions
> apt.f <- filter(apt,
+                 apt_price >= 10000) # 1억이상 아파트 가격에 거래된 자료들만 추출
> summary(apt.f$apt_price)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  10000   13950   17500   19261   23200  108000
> str(apt.f)
'data.frame':   8493 obs. of  14 variables:
 $ id             : int  17 18 19 20 21 22 23 24 25 26 ...
 $ apt_price      : int  16000 15300 12600 15500 16100 15500 15300 21000 21800
 $ area_m2        : num  60 60 60 60 60 ...

> apt.f <- filter(apt,
+                 apt_price >= 10000 & urban == "읍") # 1억이상 아파트 가격에 거래되면서 읍지역에 해당하는 자료들만 추출
> table(apt.f$urban) # 빈도

  동   면   읍
   0    0 1968
> str(apt.f)
'data.frame':   1968 obs. of  14 variables:
 $ id             : int  17 18 19 20 21 22 23 24 25 26 ...
 $ apt_price      : int  16000 15300 12600 15500 16100 15500 15300 21000 21800 21300 ...

> apt.f <- filter(apt,
+                 apt_price >= 10000 | urban == "동") # 1억이상 아파트 가격이거나 동지역에 해당하는 자료들만 추출
> table(apt.f$urban) # 빈도

  동   면   읍
8848  784 1968
> str(apt.f)
'data.frame':   11600 obs. of  14 variables:
 $ id             : int  17 18 19 20 21 22 23 24 25 26 ...
 $ apt_price      : int  16000 15300 12600 15500 16100 15500 15300 21000 21800 21300 ...
 $ area_m2        : num  60 60 60 60 60 ...
```

# 변수명 변환하기: rename()

- rename() 변수명 변환하기
  - 모든 변수들은 변하지 않음
  - R에서 변수명 변환하기는 어려운 작업임
  - rename() 함수는 변수명 변환을 쉽게 하기 위한 도구
- 실습

```
> ?rename() # Select/rename variables by name
> head(apt[ , 2:5], 4) # 2번째 부터 5번째 열까지, 4개의 행 데이터셋 확인하기
  apt_price area_m2 floor_no year_built
1      4800    39.8        2       1998
2      4500    39.8        6       1998
3      4000    39.8        7       1998
4      4000    39.8        9       1998
> apt.r <- rename(apt, # 바꾸고자 하는 객체 명
+                 price = apt_price, area = area_m2, floor = floor_no, b_year = year_built) # 변수명 바꿈
> head(apt.r[ , 2:5], 4)
  price area floor b_year
1  4800 39.8     2   1998
2  4500 39.8     6   1998
3  4000 39.8     7   1998
4  4000 39.8     9   1998
```

# 정렬하기: arrange()

- Arrange rows by variables
  - reorder rows of a data frame according to one of the variables/columns
  - simplifies the process
- 실습

```
> ## arrange()
> ?arrange # order tbl rows by an expression involving its variables.
> apt <- arrange(apt, # 정렬할 데이터 명
+                apt_price, area_m2, year_built) # 오름차순 정렬
> head(select(apt, apt_price, area_m2, year_built), 3) # 확인1
  apt_price area_m2 year_built
1      1250   39.95       1993
2      1250   39.95       1993
3      1250   39.95       1993
> tail(select(apt, apt_price, area_m2, year_built), 3) # 확인2
      apt_price area_m2 year_built
13307     97300 196.976       2010
13308    105000 196.976       2010
13309    108000 196.976       2010
```

```
> ?desc # Descending order
> apt <- arrange(apt,
+                        desc(apt_price, area_m2)) # 내림차순 정렬
> head(select(apt, apt_price, area_m2), 3)
  apt_price area_m2
1    108000 196.976
2    105000 196.976
3     97300 196.976
> tail(select(apt, apt_price, area_m2), 3)
      apt_price area_m2
13307      1250   39.95
13308      1250   39.95
13309      1250   39.95
```

# 데이터 수정 및 변형: mutate(), transmute()

- mutate()와 transmute()의 차이
  - mutate()함수는 기존 데이터를 그대로 유지하면서 새로운 변수를 추가
  - transmute() 함수는 기존 데이터를 제거하고 새로이 생성된 변수만 추가
  - 기존 변수명이 같을 경우에는 새로운 변수가 추가되면서 기존 변수에 덮어쓰기를 하게 되므로 주의
- mutate()와 transmute()에서 유용한 기능들
  - +, −, log(), etc., for their usual mathematical meanings
  - lead(), lag()
  - dense_rank(), min_rank(), percent_rank(), row_number(), cume_dist(), ntile()
  - cumsum(), cummean(), cummin(), cummax(), cumany(), cumall()
  - na_if(), coalesce()
  - if_else(), recode(), case_when()

# dplyr 패키지를 활용한 데이터 마이닝

## 데이터 수정 및 변형: mutate(), transmute()

- 실습
  - mutate()

```
> apt <- mutate(apt, # 주가할 객체 넣
+               mean_diff_price = apt_price - mean(apt_price, na.rm = TRUE)) # 아파트 평균 가격의 차이
> head(select(apt, apt_price, mean_diff_price), 3 )
  apt_price mean_diff_price
1    108000         93447.24
2    105000         90447.24
3     97300         82747.24
> summary(apt$apt_price) # 아파트 평균 요약통계
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1250    7700   13500   14553   19500  108000
> summary(apt$mean_diff_price)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 -13303   -6853   -1053       0    4947   93447
```

    - 93447.24 = 108000-14553

  - transmute()

```
> apt.tr <- transmute(apt, # 주가할 객체 넣
+                     mean_diff_price = apt_price - mean(apt_price, na.rm = TRUE), # 아파트 평균 가격의 차이
+                     mean_diff_area = area_m2 - mean(area_m2, na.rm = TRUE)) # 아파트 평균 전용 면적의 차이
> head(apt.tr, 5) # 첫번째 부터 다섯 째 행까지만 데이터 보여주기
  mean_diff_price mean_diff_area
1        93447.24      128.05387
2        90447.24      128.05387
3        82747.24      128.05387
4        53447.24       93.70387
5        52447.24       63.01887
```

# 집단별 데이터 분할하기: group_by()

- 변수(들)별 분할(집계화)
  - group_by() takes an existing tbl and converts it into a grouped tbl where operations are performed "by group".
    - 집단별로 요약 통계를 생성할 때 사용
    - 복귀
      - ungroup() : removes grouping.
- **Usage**
  - group_by(.data, ..., add = FALSE, .drop = FALSE)
  - ungroup(x, ...)

| | |
|---|---|
| `.data` | a tbl |
| `...` | Variables to group by. All tbls accept variable names. Some tbls will accept functions of variables. Duplicated groups will be silently dropped. |
| `add` | When `add = FALSE`, the default, `group_by()` will override existing groups. To add to the existing groups, use `add = TRUE`. |
| `.drop` | When `.drop = TRUE`, empty groups are dropped. |
| `x` | A `tbl()` |

# 집단별 데이터 분할하기: group_by()

- 실습
  - 데이터를 집단으로 분할: group_by()
    - 건축년도별 데이터를 리스트로 분할

```
> years <- group_by(apt, # 변수의 집단별 분할할 객체명
+                   year_built) # 건축 연도별 매트릭스 형태의 리스트 형성
> str(years) #
Classes 'grouped_df', 'tbl_df', 'tbl' and 'data.frame': 13309 obs. of  15 v
 $ id             : int  10349 10323 10316 10299 9156 10361 10324 9147 1030
 $ apt_price      : int  108000 105000 97300 68000 67000 64500 64000 63000
 $ area_m2        : num  197 197 197 163 132 ...
 $ floor_no       : int  41 42 42 45 23 39 24 24 6 29 ...
 $ year_built     : int  2010 2010 2010 2010 2015 2010 2010 2015 2010 2018
 $ ym_sale        : int  201905 201902 201901 201810 201901 201907 201902 2
 $ day_sale       : int  25 13 13 18 10 19 20 28 3 11 ...
 $ urban          : Factor w/ 3 levels "동","면","읍": 1 1 1 1 1 1 1 1 1 1 .
 $ apt_complex    : Factor w/ 802 levels "(1028-0)","(142-1)",..: 373 373 3
 $ address        : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리",..: 142
 $ address_bunji  : Factor w/ 873 levels "1","1-1","1-16",..: 426 426 426 4
 $ address_sido   : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1 ...
 $ address_sigungu: Factor w/ 14 levels "괴산군","단양군",..: 13 13 13 13 12 1
 $ address_dong   : Factor w/ 107 levels "가경동","감곡면",..: 40 40 40 40 90
 $ mean_diff_price: num  93447 90447 82747 53447 52447 ...
 - attr(*, "groups")=Classes 'tbl_df', 'tbl' and 'data.frame':  43 obs. of
  ..$ year_built: int  1977 1978 1979 1980 1981 1982 1983 1984 1985 1986 ..
  ..$ .rows     : List of 43
  .. ..$ : int  7811 8584 8821
  .. ..$ : int  7922 9101 9127 9452 9630 9834 9857
> class(years)
[1] "grouped_df" "tbl_df"     "tbl"        "data.frame"
```

# 데이터 마이닝: %>% (파이프 연산자)

- R 프로그래밍에서의 작업
  - 프로그래밍(코딩)할 때, 복잡한 작업
    - 함수의 결과를 다시 다른 함수에 넣고 그 결과를 다시 함수에 넣는 작업
      - third(second(first(x)))
    - 수 많은 괄호 생성으로 수정 번거롭고, 이해하기 어려움 발생
- dplyr패키지에서의 pipe operator 사용으로 해결
  - 파이프 연산자는 괄호의 괄호 등보다 직관적이고 사용이 편리
- Dplyr패키지의 함수들을 "%>%"로 일련의 연속된 작업 수행
  - 왼쪽부터 순차적으로 실행하고 그 반환 결과를 다음의 함수로 실행
- 예:
    - 일반적인 작업 절차: third(second(first(x)))
    - %>% 작업 절차: first(x) %>% second %>% third

# 데이터 마이닝: %>% (파이프 연산자)

- 실습
  - apt 데이터에서 apt_price가 평균보다 큰 데이터만 추출
  - apt 데이터에서 apt_price가 평균보다 2배 큰 데이터만 추출한 후 apt_price부터 area_m2 변수들만 선택하고, 이를 다시 area_m2의 내림차순 정렬

```
> a <-apt %>% filter(apt_price > mean(apt_price, na.rm = TRUE))
> str(a)
'data.frame':   5944 obs. of  15 variables:
 $ id            : int  10349 10323 10316 10299 9156 10361 1032
 $ apt_price     : int  108000 105000 97300 68000 67000 64500 6
 $ area_m2       : num  197 197 197 163 132 ...
 $ floor_no      : int  41 42 42 45 23 39 24 24 6 29 ...
 $ year_built    : int  2010 2010 2010 2010 2015 2010 2010 2015

> #** 1. apt 데이터에서
> #** 2. apt_price가 평균보다 2배 큰 데이터만 추출한 후
> #** 3. apt_price부터 area_m2 변수들만 선택하고,
> #** 4.이를 다시 area_m2의 내림차순 정렬
> b <- apt %>% # 1
+   filter(apt_price > mean(apt_price, na.rm = TRUE)*2) %>% # 2
+   select(apt_price:area_m2) %>% # 3
+   arrange(desc(area_m2)) # 4
> str(b)
'data.frame':   766 obs. of  2 variables:
 $ apt_price: int  31000 46700 108000 105000 97300 59500 33500 33000 32000 46000
 $ area_m2  : num  244 219 197 197 197 ...
> head(b)
  apt_price  area_m2
1     31000 244.0710
2     46700 219.0313
3    108000 196.9760
4    105000 196.9760
5     97300 196.9760
6     59500 196.0430
```

dplyr 패키지를 활용한 데이터 마이닝

# 데이터 요약하기: sumr

- 집단별 요약통계: summarise()
  - group_by()함수에 이어 사용되어짐
- 실습1:
  - 건축년도별 아파트 거래가격의 평균과 거래건수
- 실습2:
  - 건축년도별 읍면동(urban)별 아파트 건수와 아파트 평균 가격 통계

```
> apt %>% # 데이터 선택
+   group_by(year_built) %>% # 건축년도별 자료 리스트 작성
+   summarise(ave_price = mean(apt_price), sale_freq = n()) # 요약 통계
# A tibble: 43 x 3
   year_built ave_price sale_freq
        <int>     <dbl>     <int>
 1       1977    10017.         3
 2       1978     8729.         7
 3       1979     5105.        44
 4       1980     3706.        27
 5       1981     4509.        37
 6       1982     8215         20
 7       1983    10282.        25
 8       1984     7597.        33
 9       1985     6988.        75
10       1986     5926.       138
# ... with 33 more rows

> # 건축년도별 읍면동(urban)별 아파트 건수와 아파트 평균 가격 통계
> x <- apt %>%
+         group_by(year_built, urban) %>%
+         summarise(ave_price = mean(apt_price), sale_freq = n())
> x
# A tibble: 110 x 4
# Groups:   year_built [43]
   year_built urban ave_price sale_freq
        <int> <fct>     <dbl>     <int>
 1       1977 동       10017.         3
 2       1978 동        8729.         7
 3       1979 동        5105.        44
 4       1980 동        3706.        27
 5       1981 동        4509.        37
 6       1982 동        8215         20
 7       1983 동       10741.        23
 8       1983 읍        5000         2
 9       1984 동        7597.        33
10       1985 동        8339.        49
# ... with 100 more rows
> table(x$urban)

동 면 읍
43 31 36
```

# dplyr 패키지를 활용한 데이터 마이닝

보완 강의

## 데이터 수정하기: 색인[], transform(), recode()

- 색인 [ ] 활용
  - apt$year_sale[apt$ym_sale > 201812] <- 2019 # year_sale 변수생성
  - apt$year_sale[apt$ym_sale <= 201812] <- 2018
- 연속형 변수를 구간 변수로 생성: recode()
  - cuts <- "1250:7700 =1 ; 7701:13500 =2 ; 13501:19500 =3 ; 19501:108000 =4"
  - apt_price5gr <- recode (apt$apt_price, cuts)
- transform() 함수 활용
  - apt <- transform(apt, new = ifelse(year_built <2000, "old", "new"))

```
> #* 아파트 거래년도 변수 생성 후 값 변경: [ ] 활용
> apt$year_sale[apt$ym_sale > 201812] <- 2019 # year_sale 변수생성
> apt$year_sale[apt$ym_sale <= 201812] <- 2018
> table(apt$year_sale)

2018 2019
4341 8968
>
> #* 연속형 변수를 구간 변수로 생성: recode()
> ?recode
> summary(apt$apt_price)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1250    7700   13500   14553   19500  108000
>
> cuts <-  "1250:7700 =1 ; 7701:13500 =2 ; 13501:19500 =3 ; 19501:108000 =4"
> apt_price5gr <- recode (apt$apt_price, cuts)
> table(apt_price5gr)
apt_price5gr
   1    2    3    4
3347 3409 3228 3325
>
> #* transfor() 함수 활용
> ?transform
> apt <- transform(apt, new = ifelse(year_built <2000, "old", "new"))
> table(apt$new) # 일원 빈도분포표

 new  old
7097 6212
> table(apt$new, apt$urban) # 이원 빈도분포표

       동   면   읍
  new 3949  941 2207
  old 4899  391  922
```

# dplyr 패키지를 활용한 데이터 마이닝

보완 강의

## 기타 함께 사용하는 유용한 함수들: distinct(), between(), row_number(), n()

- 열(변수)의 행 고유값 선택하기: distinct()
  - 고유한 항목의 값을 찾는 데 사용
- 조건범위 설정 함수: between()
  - 데이터의 열(변수)내에서 from ~ to에서 범위 조건을 찾는 데 사용

```
> apt %>% distinct(urban)
  urban
1    읍
2    면
3    동
> apt %>% distinct(address_sigungu)
   address_sigungu
1           괴산군
2           단양군
3           보은군
4           영동군
5           옥천군
6           음성군
7           제천시
8           증평군
9           진천군
10      청주상당구
11      청주서원구
12      청주청원구
13      청주흥덕구
14          충주시
```

```
> apt %>% select(id:ym_sale) %>% filter(between(apt_price, 10000, 30000)) %>% summary() # 10000 <= apt_price <=30000
       id          apt_price       area_m2          floor_no       year_built      ym_sale
 Min.   :   17   Min.   :10000   Min.   : 26.31   Min.   : 1.000   Min.   :1977   Min.   :201809
 1st Qu.: 3828   1st Qu.:13600   1st Qu.: 59.98   1st Qu.: 5.000   1st Qu.:1999   1st Qu.:201811
 Median : 6728   Median :16900   Median : 84.57   Median : 9.000   Median :2006   Median :201903
 Mean   : 6671   Mean   :17776   Mean   : 77.63   Mean   : 9.673   Mean   :2006   Mean   :201873
 3rd Qu.: 9430   3rd Qu.:22000   3rd Qu.: 84.96   3rd Qu.:13.000   3rd Qu.:2016   3rd Qu.:201906
 Max.   :13309   Max.   :30000   Max.   :203.16   Max.   :48.000   Max.   :2019   Max.   :201908
> apt %>% select(id:ym_sale) %>% filter(apt_price >= 10000 & apt_price <= 30000) %>% summary() # 위와 동일
       id          apt_price       area_m2          floor_no       year_built      ym_sale
 Min.   :   17   Min.   :10000   Min.   : 26.31   Min.   : 1.000   Min.   :1977   Min.   :201809
 1st Qu.: 3828   1st Qu.:13600   1st Qu.: 59.98   1st Qu.: 5.000   1st Qu.:1999   1st Qu.:201811
 Median : 6728   Median :16900   Median : 84.57   Median : 9.000   Median :2006   Median :201903
 Mean   : 6671   Mean   :17776   Mean   : 77.63   Mean   : 9.673   Mean   :2006   Mean   :201873
 3rd Qu.: 9430   3rd Qu.:22000   3rd Qu.: 84.96   3rd Qu.:13.000   3rd Qu.:2016   3rd Qu.:201906
 Max.   :13309   Max.   :30000   Max.   :203.16   Max.   :48.000   Max.   :2019   Max.   :201908
```

# dplyr 패키지를 활용한 데이터 마이닝

보완 강의

기타 함께 사용하는 유용한 함수들:
distinct(), between(), row_number(), n()

- 데이터의 순차적 숫자 값 부여: row_number()

```
> apt %>% select(id:floor_no)%>% mutate(id_number = row_number()) %>% head(4)
  id apt_price area_m2 floor_no id_number
1  1      4800    39.8        2         1
2  2      4500    39.8        6         2
3  3      4000    39.8        7         3
4  4      4000    39.8        9         4
```

- 데이터의 건수를 구하는 데 사용: n()

```
> apt %>% group_by(urban) %>% summarize(n())
# A tibble: 3 x 2
  urban `n()`
  <fct> <int>
1 동     8848
2 면     1332
3 읍     3129
```

보완 강의

# 데이터 병합(join)

- 데이터의 병합: join() 관련 함수
  - join two tbls together
    - x and y should usually be from the same data source
  - join() 함수 유형들
    - inner_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), ...)
    - left_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), ...)
    - right_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), ...)
    - full_join(x, y, by = NULL, copy = FALSE, suffix = c(".x", ".y"), ...)
    - semi_join(x, y, by = NULL, copy = FALSE, ...)
    - nest_join(x, y, by = NULL, copy = FALSE, keep = FALSE, name = NULL, ...)
    - anti_join(x, y, by = NULL, copy = FALSE, ...)
  - 인수들 설명
    - x, y : 병합할 객체(데이터)들
    - by : 병합될 때의 기준 변수들

보완 강의

# 데이터 병합(join)

- 데이터의 병합: left_join( )
  - 기준 데이터(df.x)로 병합하고, 일치하지 않는 준거 데이터(df.y)는 제거

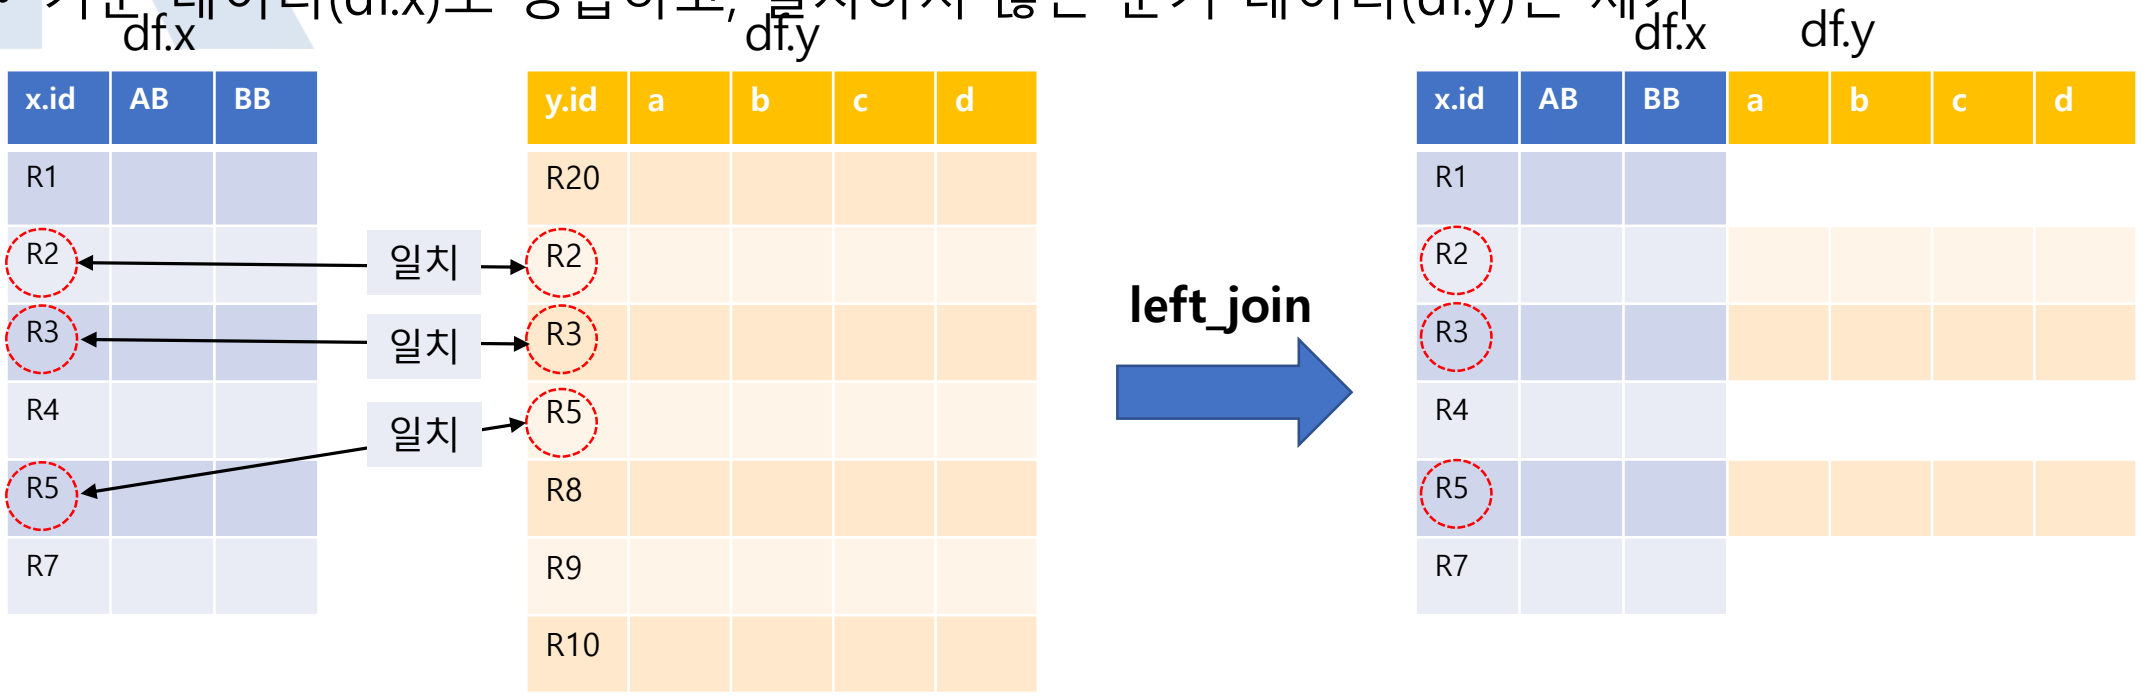

보완 강의

# 데이터 병합(join)

- 데이터의 병합: right_join( )
  - 준거 데이터(df.y)를 기준으로 병합하고, 일치하지 않는 기준 데이터(df.x)는 제거

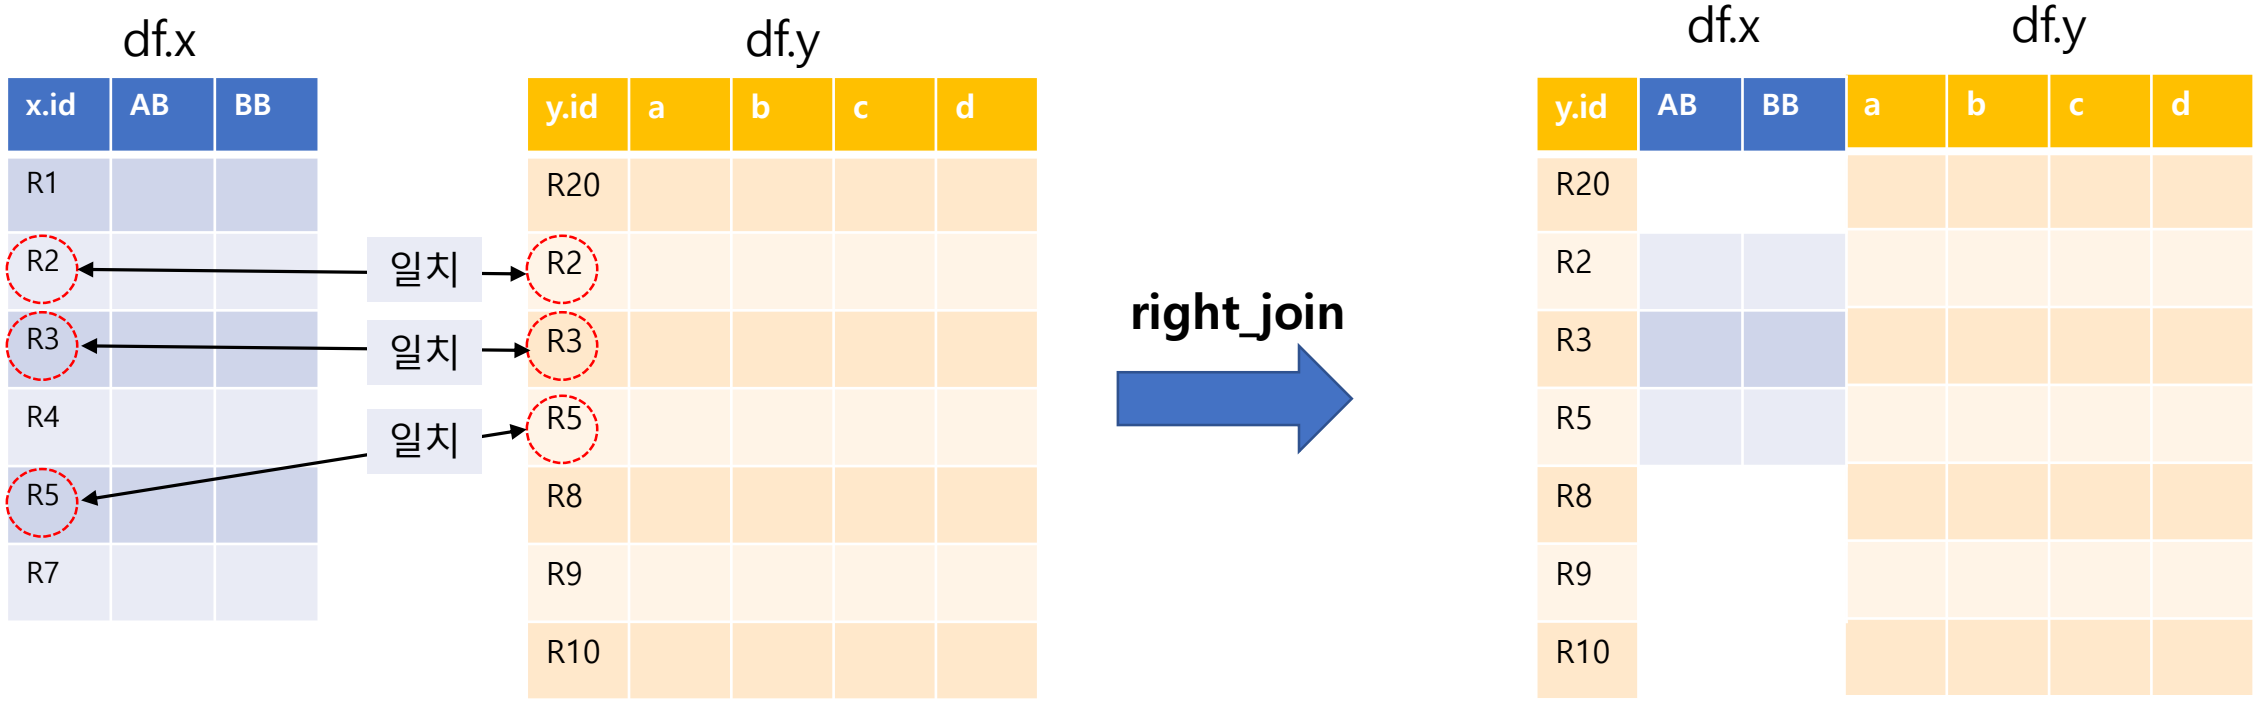

보완 강의

# 데이터 병합(join)

- 데이터의 병합: inner_join( )
  - 기준 데이터(df.x)와 준거 데이터(df.y)와 모두 일치하는 데이터셋 만 병합하고, 모두 제거

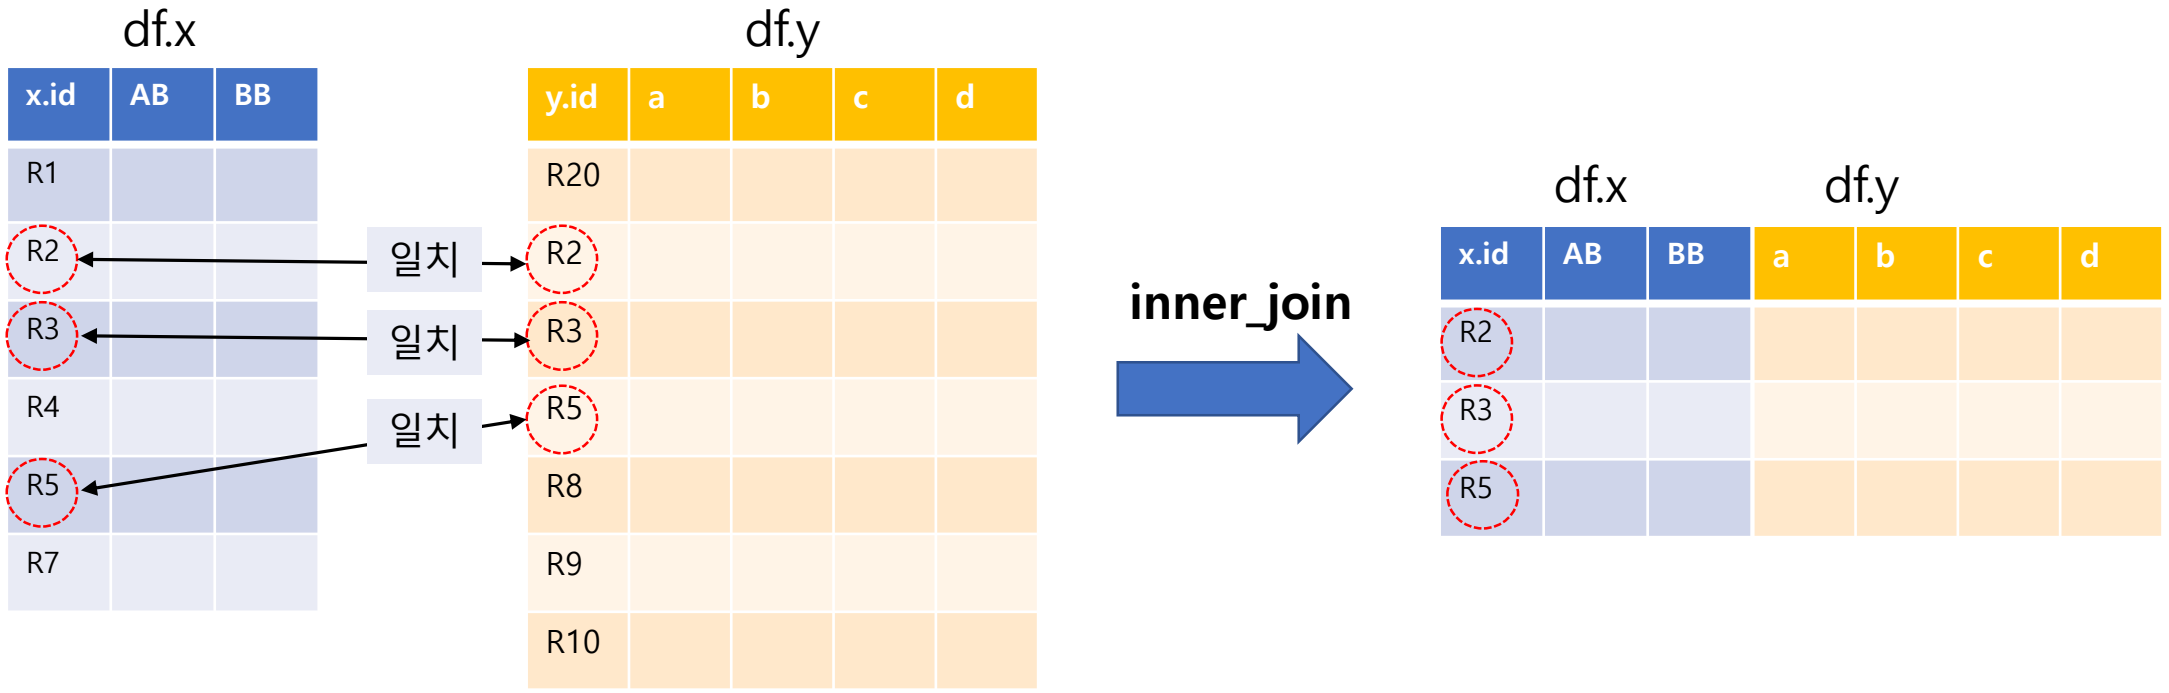

보완 강의

# 데이터 병합(join)

- 데이터의 병합: full join( )
  - 기준 데이터(df.x)로 일치하지 않는 데이터도 모두 병합

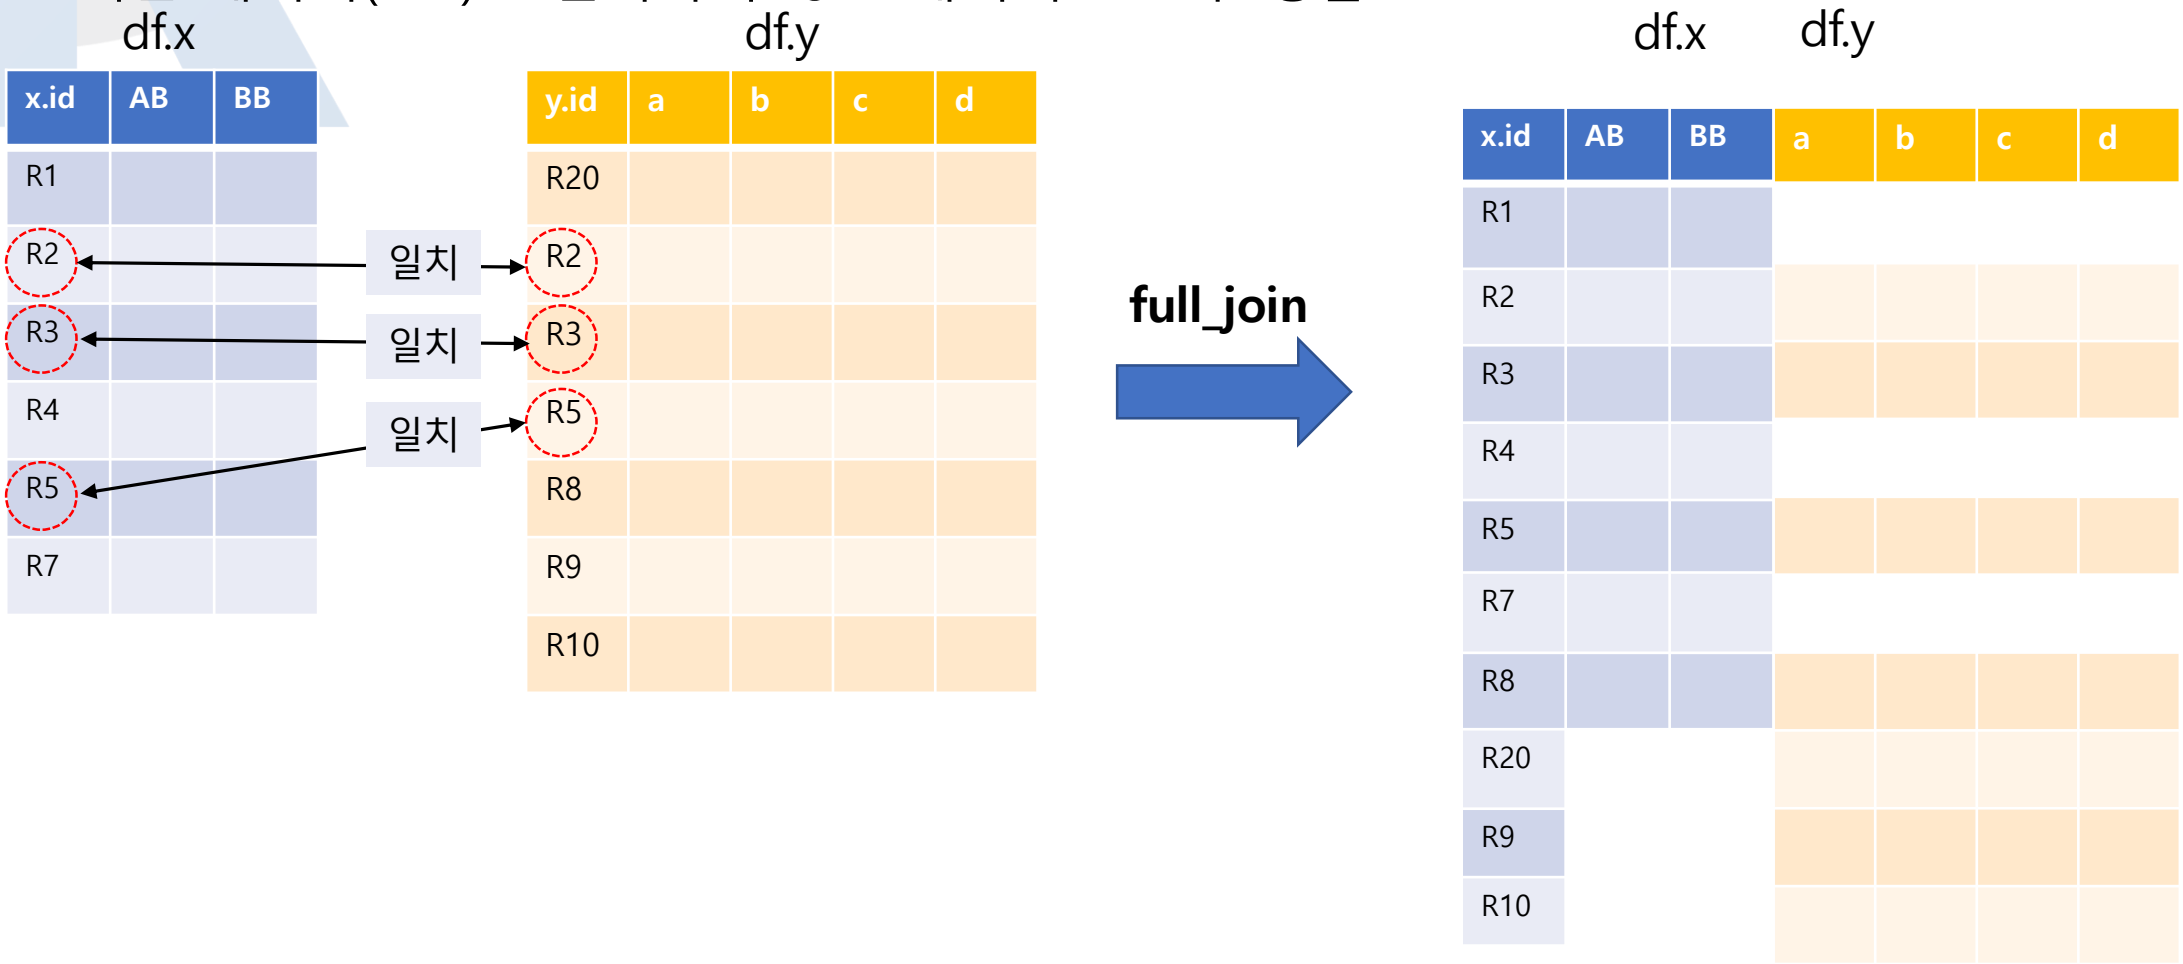

보완 강의

# 데이터 병합(join)

- 데이터의 병합: full join( )
  - 기준 데이터(df.x)에서 준거 데이터(df.y)와 일치하지 않는 데이터 이외 제거

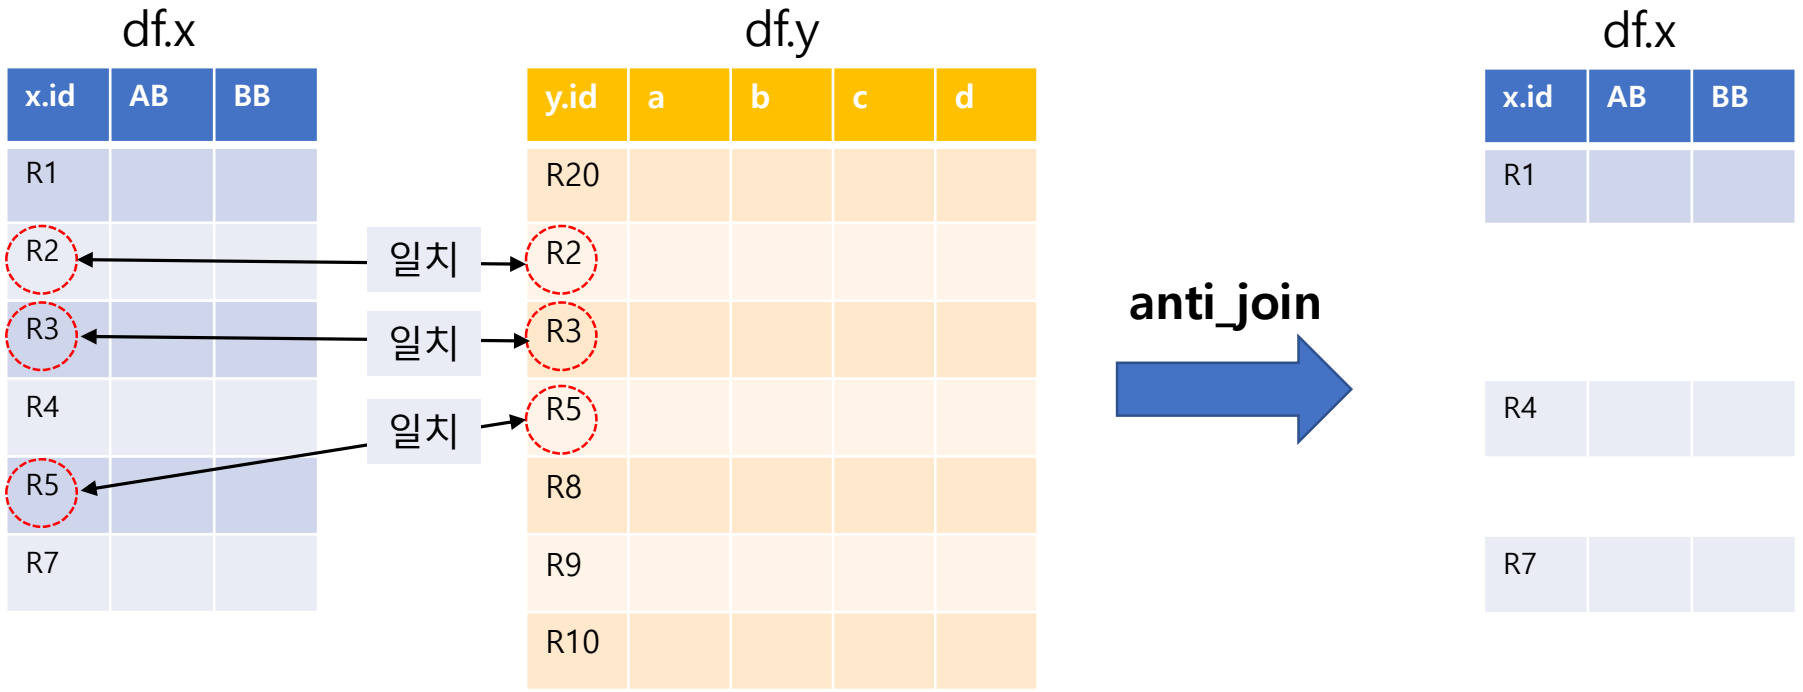

보완 강의

# 데이터 병합(join)

- 실습: 충청북도 아파트 실거래 자료(df.x)와 전국 시군구 통계자료(df.y) 병합
  - df.x
    - 데이터 구조 및 변수 속성 확인

```
> df.x <- apt # 충청북도 아파트 실거래 자료
> str(df.x)
'data.frame':   13309 obs. of  14 variables:
 $ id              : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price       : int  4800 4500 4000 4000 400(
 $ area_m2         : num  39.8 39.8 39.8 39.8 39.8
 $ floor_no        : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built      : int  1998 1998 1998 1998 1998
 $ ym_sale         : int  201811 201811 201812 201
 $ day_sale        : int  6 13 10 10 10 10 10 10 1
 $ urban           : Factor w/ 3 levels "동","면",
 $ apt_complex     : Factor w/ 802 levels "(1028-(
 $ address         : Factor w/ 181 levels "충청북도
 $ address_bunji   : Factor w/ 873 levels "1","1-1
 $ address_sido    : Factor w/ 1 level "충청북도":
 $ address_sigungu: Factor w/ 14 levels "괴산군",'
 $ address_dong    : Factor w/ 107 levels "가경동",
```

    - 시군구명 고유값 확인

```
> df.x %>% distinct(address_sigungu)
   address_sigungu
1           괴산군
2           단양군
3           보은군
4           영동군
5           옥천군
6           음성군
7           제천시
8           증평군
9           진천군
10      청주상당구
11      청주서원구
12      청주청원구
13      청주흥덕구
14          충주시
```

보완 강의

# 데이터 병합(join)

- 실습: 충북 아파트 실거래 자료(df.x)와 시군구 통계자료(df.y) 병합
  - df.y
    - 충청북도에 해당하는 데이터만 추출

```
> library(readxl)
> df <- sigungu_data <- read_excel("data_by_sigungu_2018.xlsx") # 전국 시군구 통계 엑셀 데이터 불러오기
> df.y <- df %>% filter(sido == "충청북도") # 충청북도 해당 자료만 추출
```

    - 데이터 구조 및 변수 속성 확인

```
> str(df.y) # sido와 sigungu의 변수명과 속성(분자)가 df.x의 변수명과 속성(Factor)
Classes 'tbl_df', 'tbl' and 'data.frame':       15 obs. of  16 variables:
 $ id                 : num  142 143 144 145 146 147 148 149 150 151 ...
 $ sido               : chr  "충청북도" "충청북도" "충청북도" "충청북도" ...
 $ sigungu            : chr  "충주시" "제천시" "청주시" "상당구" ...
 $ area               : num  984 884 940 NA NA ...
 $ pop_density        : num  212 155 888 NA NA ...
 $ pop_tot            : num  835590 216782 193767 171129 253912 ...
 $ pop_male           : num  419676 107632 98536 85402 128106 ...
 $ pop_female         : num  415914 109150 95231 85727 125806 ...
 $ age_average        : chr  "43.6" "44.6" "39.799999999999997" "42" ...
 $ r_aged             : num  17.8 19.2 11.8 NA NA ...
 $ pop_net_move       : num  232 56 -90 NA NA NA NA 4 -4 23 ...
 $ housing            : num  88082 56261 283664 60650 72244 ...
 $ apt_sale_price     : num  98.9 99.5 98.6 NA NA NA NA NA NA NA ...
 $ apt_junse_price    : num  97.8 98.8 99.7 NA NA NA NA NA NA NA ...
 $ car                : num  0.51 0.51 0.48 NA NA NA NA 0.55 0.53 0.5 ...
 $ accident_per_1000car: num  10.9 11.9 11 NA NA ...
```

    - 시군구명 고유값 확인

```
> df.y %>% distinct(sigungu) # 시군구
# A tibble: 15 x 1
   sigungu
   <chr>
 1 충주시
 2 제천시
 3 청주시
 4 상당구
 5 서원구
 6 흥덕구
 7 청원구
 8 부은구
```

보완 강의

# 데이터 병합(join)

- 일치시킬 기준 변수명과 고유값 확인
- 시군구명 고유값 비교
  - df.x vs. df.y

```
> df.x %>% distinct(address_sigungu)
   address_sigungu
1             괴산군
2             단양군
3             보은군
4             영동군
5             옥천군
6             음성군
7             제천시
8             증평군
9             진천군
10        청주상당구
11        청주서원구
12        청주청원구
13        청주흥덕구
14            충주시
```

일치?

```
> df.y %>% distinct(sigungu)
# A tibble: 15 x 1
   sigungu
   <chr>
 1 충주시
 2 제천시
 3 청주시
 4 상당구
 5 서원구
 6 흥덕구
 7 청원구
 8 보은군
 9 옥천군군
10 영동군군
11 진천군군
12 괴산군군
13 음성군군
14 단양군군
15 증평군
```

- 시군구별 변수명 불일치
  - df.x = “address_sigungu”
  - df.y = “sigungu”
    - 위의 것으로 일치시킴
    - rename() 함수

```
> df.y <- rename(df.y, address_sigungu = sigungu)
> names(df.y) # 변수명 확인
 [1] "id"                  "sido"                "address_sigungu"
 [6] "pop_tot"             "pop_male"            "pop_female"
[11] "pop_net_move"        "housing"             "apt_sale_price"
[16] "accident_per_1000car"
```

보완 강의

# 데이터 병합(join)

- 실습: left_join()

```
> j_left <- left_join(df.x, df.y, # 병합할 데이터들
+           by = c('address_sigungu')) # 병합 기준 열(변수)명
Error: `by` can't contain join column `address_sigungu` which i
Call `rlang::last_error()` to see a backtrace
> str(j_left)
'data.frame':   13309 obs. of  28 variables:
 $ id.x              : int  1 2 3 4 5 6 7 8 9 10 ...
 $ apt_price         : int  4800 4500 4000 4000 4000 4000 400
 $ area_m2           : num  39.8 39.8 39.8 39.8 39.8 39.8 39.
 $ floor_no          : int  2 6 7 9 3 7 5 9 8 5 ...
 $ year_built        : int  1998 1998 1998 1998 1998 1998 199
 $ ym_sale           : int  201811 201811 201812 201812 20181
 $ day_sale          : int  6 13 10 10 10 10 10 10 10 10 ...
 $ urban             : Factor w/ 3 levels "동","면","읍": 3 3
 $ apt_complex       : Factor w/ 802 levels "(1028-0)","(142-
 $ address           : Factor w/ 181 levels "충청북도 괴산군 괴
 $ address_bunji     : Factor w/ 873 levels "1","1-1","1-16",
 $ address_sido      : chr  "충청북도" "충청북도" "충청북도" "충청
 $ address_sigungu   : chr  "괴산군" "괴산군" "괴산군" "괴산군" .
 $ address_dong      : Factor w/ 107 levels "가경동","감곡면",.
 $ id.y              : num  153 153 153 153 153 153 153 153 1
 $ area              : num  407 407 407 407 407 ...
 $ pop_density       : num  172 172 172 172 172 ...
 $ pop_tot           : num  73677 73677 73677 73677 73677 ...
 $ pop_male          : num  38314 38314 38314 38314 38314 ...
 $ pop_female        : num  35363 35363 35363 35363 35363 ...
```

```
> j_left %>% distinct(address_sigungu)
   address_sigungu
1              괴산군
2              단양군
3              보은군
4              영동군
5              옥천군
6              음성군
7              제천시
8              증평군
9              진천군
10         청주상당구
11         청주서원구
12         청주청원구
13         청주흥덕구
14             충주시
```

보완 강의

# 데이터 병합(join)

- 실습: right_join()

```
> j_right <- right_join(df.x, df.y, # 병합할 데이터들
+                       by = c('address_sigungu')) # 병합 기준 열(변수)명
Warning message:
Column `address_sigungu` joining factors with different levels, coercing
> str(j_right)
'data.frame':   5495 obs. of  29 variables:
 $ id.x               : int  11612 11613 11614 11615 11616 11617 11618 1
 $ apt_price          : int  4600 4500 5000 4000 4600 3800 4200 3900 390
 $ area_m2            : num  69.2 35.5 35.2 35 35 ...
 $ floor_no           : int  2 3 2 2 1 5 3 5 3 5 ...
 $ year_built         : int  1989 1979 1979 1979 1979 1979 1979 1979 197
 $ ym_sale            : int  201901 201809 201809 201809 201810 201810 2
 $ day_sale           : int  19 6 14 19 4 24 1 9 9 20 ...
 $ urban              : Factor w/ 3 levels "동","면","읍": 1 1 1 1 1 1 1
 $ apt_complex        : Factor w/ 802 levels "(1028-0)","(142-1)",..: 31
 $ address            : Factor w/ 181 levels "충청북도 괴산군 괴산읍 대사리"
 $ address_bunji      : Factor w/ 873 levels "1","1-1","1-16",..: 17 600
 $ address_sido       : Factor w/ 1 level "충청북도": 1 1 1 1 1 1 1 1 1 1
 $ address_sigungu    : chr  "충주시" "충주시" "충주시" "충주시" ...
 $ address_dong       : Factor w/ 107 levels "가경동","감곡면",..: 11 11 1
 $ id.y               : num  142 142 142 142 142 142 142 142 142 142 ...
 $ sido               : chr  "충청북도" "충청북도" "충청북도" "충청북도" ...
 $ area               : num  984 984 984 984 984 ...
```

```
> j_right %>% filter(sido == "충청북도") %>% distinct(address_sigungu)
   address_sigungu
1             충주시
2             제천시
3             청주시
4           상당구
5           서원구
6           흥덕구
7           청원구
8             보은군
9             옥천군
10            영동군
11            진천군
12            괴산군
13            음성군
14            단양군
15            증평군
```

이외 full_join(), anti_join() 등은 직접 실습을 해보기 바람

보완 강의

# 연습문제 *(보완)

- Df.x와 df.y의 시군구 명(address_sigungu)이 아래와 같이 서로 일치하지 않는다. df.y의 4개 시군구명으로 df.x 데이터에서 시군구명으로 바꾸고자 한다. 어떻게 하면 될까요? 토의 해 봅시다.
  - 즉, 청주상당구 → 상당구, 청주서원구 → 서원구, 청주청원구 → 청원구, 청주흥덕구 → 흥덕구

df.x

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 영동군 |
| 5 | 옥천군 |
| 6 | 음성군 |
| 7 | 제천시 |
| 8 | 증평군 |
| 9 | 진천군 |
| 10 | 청주상당구 |
| 11 | 청주서원구 |
| 12 | 청주청원구 |
| 13 | 청주흥덕구 |
| 14 | 충주시 |

df.y

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 상당구 |
| 5 | 서원구 |
| 6 | 영동군 |
| 7 | 옥천군 |
| 8 | 음성군 |
| 9 | 제천시 |
| 10 | 증평군 |
| 11 | 진천군 |
| 12 | 청원구 |
| 13 | 청주시 |
| 14 | 충주시 |
| 15 | 흥덕구 |

1. recode() 함수 활용
   - 위의 함수는 dplyr과 car 패키지에 있음
2. 조건문 활용
3. 색인 활용 등

보완 강의

# 연습문제 *(보완)

- df.y 시군구명에서 “청주시 " 는 df.x에 없다.  Df.y의 시군구 데이터에서 “청주시”는 제거하고자 한다. 어떻게 하면 될까요? 토의 해봅시다.

df.x

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 영동군 |
| 5 | 옥천군 |
| 6 | 음성군 |
| 7 | 제천시 |
| 8 | 증평군 |
| 9 | 진천군 |
| 10 | 청주상당구 |
| 11 | 청주서원구 |
| 12 | 청주청원구 |
| 13 | 청주흥덕구 |
| 14 | 충주시 |

df.y

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 상당구 |
| 5 | 서원구 |
| 6 | 영동군 |
| 7 | 옥천군 |
| 8 | 음성군 |
| 9 | 제천시 |
| 10 | 증평군 |
| 11 | 진천군 |
| 12 | 청원구 |
| 13 | 청주시 |
| 14 | 충주시 |
| 15 | 흥덕구 |

보완 강의

# 연습문제 *(보완)

- df.y 시군구명에서 “청주시 " 는 df.x에 없다.  Df.y의 시군구 데이터에서 “청주시”는 제거하고자 한다. 어떻게 하면 될까요? 토의 해봅시다.

df.x

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 영동군 |
| 5 | 옥천군 |
| 6 | 음성군 |
| 7 | 제천시 |
| 8 | 증평군 |
| 9 | 진천군 |
| 10 | 청주상당구 |
| 11 | 청주서원구 |
| 12 | 청주청원구 |
| 13 | 청주흥덕구 |
| 14 | 충주시 |

df.y

| | address_sigungu |
|---|---|
| 1 | 괴산군 |
| 2 | 단양군 |
| 3 | 보은군 |
| 4 | 상당구 |
| 5 | 서원구 |
| 6 | 영동군 |
| 7 | 옥천군 |
| 8 | 음성군 |
| 9 | 제천시 |
| 10 | 증평군 |
| 11 | 진천군 |
| 12 | 청원구 |
| 13 | 청주시 |
| 14 | 충주시 |
| 15 | 흥덕구 |

보완 강의

# 연습문제 *(보완)

- 시군구명(address_sigungu)이 일치하는 df.x와 df.y를 full_join()함수로 병합하여 df.xy 객체에 할당하고자 한다. 어떻게 하면 될까요?

- 그리고, 그 결과를 앞서의 left_join과 right_join의 결과와 비교하여 토의 해봅시다.

# tbl_df() 소개

- The tbl_df class is a subclass of data.frame, created in order to have different default behaviour.
  - The colloquial term "tibble" refers to a data frame that has the tbl_df class.
  - Tibble is the central data structure for the set of packages known as the tidyverse, including dplyr, ggplot2, tidyr, and readr.

- Objects of class tbl_df have:
  - A class attribute of c("tbl_df", "tbl", "data.frame").
  - A base type of "list", where each element of the list has the same NROW().
  - A names attribute that is a character vector the same length as the underlying list.

# dplyr 패키지를 활용한 데이터 마이닝

## tbl_df() 소개

- tbl_df (*tibble diff라고도 함*)
  - 데이터 프레임 의 변형
  - tibble 패키지로 구현 예
    - install.packages("tibble")
    - library(tibble)
      - mtcars_tbl <- as_data_frame(mtcars) 또는
      - mtcars_tbl <- tbl_df(mtcars)
- data.frames와 tbl_dfs의 차이점
  - 인쇄 된 출력에는 표의 크기 요약
  - 각 열의 유형
  - 제한된 수의 행 인쇄
- dplyr 패키지의 많은 함수는 group_by() 와 같은 tbl_dfs로 자연스럽게 작동

```
# A tibble: 32 x 11
     mpg   cyl  disp    hp  drat    wt  qsec    vs    am  gear  carb
*  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1   21.0     6 160.0   110  3.90 2.620 16.46     0     1     4     4
2   21.0     6 160.0   110  3.90 2.875 17.02     0     1     4     4
3   22.8     4 108.0    93  3.85 2.320 18.61     1     1     4     1
4   21.4     6 258.0   110  3.08 3.215 19.44     1     0     3     1
5   18.7     8 360.0   175  3.15 3.440 17.02     0     0     3     2
6   18.1     6 225.0   105  2.76 3.460 20.22     1     0     3     1
7   14.3     8 360.0   245  3.21 3.570 15.84     0     0     3     4
8   24.4     4 146.7    62  3.69 3.190 20.00     1     0     4     2
9   22.8     4 140.8    95  3.92 3.150 22.90     1     0     4     2
10  19.2     6 167.6   123  3.92 3.440 18.30     1     0     4     4
# ... with 22 more rows
```

# dplyr 패키지를 활용한 데이터 마이닝

## tbl_df() 소개

- 실습

```
## tbl_df()
?tibble
?tbl_df
?as_data_frame

library(tibble)
mtcars

(mtcars_tbl <- as_data_frame(mtcars))

(mtcar_tbl2 <- tbl_df(mtcars))
```

```
> x <- select(apt, apt_price:urban) # apt_price부터 urban 열까지 추출
> x
    apt_price  area_m2 floor_no year_built ym_sale day_sale urban
1      108000 196.9760       41       2010  201905       25     동
2      105000 196.9760       42       2010  201902       13     동
3       97300 196.9760       42       2010  201901       13     동
4       68000 162.6260       45       2010  201810       18     동
5       67000 131.9410       23       2015  201901       10     동
6       64500 152.6520       39       2010  201907       19     동
7       64000 152.6520       24       2010  201902       20     동
8       63000 131.9410       24       2015  201809       28     동
9       60800 152.6520        6       2010  201811        3     동
10      60000 108.4651       29       2018  201905       11     동
11      60000 152.6520       19       2010  201809        1     동
12      60000 152.6520       30       2010  201812       29     동
13      60000 152.6520       28       2010  201904       10     동
```

```
> (x_tbl <- tbl_df(x)) # tibble 데이터 셋으로 변환
# A tibble: 13,309 x 7
   apt_price area_m2 floor_no year_built ym_sale day_sale urban
       <int>   <dbl>    <int>      <int>   <int>    <int> <fct>
 1    108000    197.       41       2010  201905       25 동
 2    105000    197.       42       2010  201902       13 동
 3     97300    197.       42       2010  201901       13 동
 4     68000    163.       45       2010  201810       18 동
 5     67000    132.       23       2015  201901       10 동
 6     64500    153.       39       2010  201907       19 동
 7     64000    153.       24       2010  201902       20 동
 8     63000    132.       24       2015  201809       28 동
 9     60800    153.        6       2010  201811        3 동
10     60000    108.       29       2018  201905       11 동
# ... with 13,299 more rows
```

# 연습문제 07

- apt 객체에서 읍면동(urban)별 거래된 아파트 가격(apt_price)의 최댓값과 전용면적(area_m2)의 최댓값을 구하시오.

# 연습문제 08

- apt 객체에서 충주시(address_sigungu==“충주시”)에서 전용면적(area_m2)이 100보다 크거나 같고 apt_price가 20000보다 크게 거래된 데이터를 추출하고 싶다. 이에 대한 함수(명령문)을 적고, 총 몇 개의 거래건수가 있는 지 적으시오.

# 연습문제 09

- apt 객체에서 1979년도에 건축된 아파트의 거래건수와 거래된 아파트의 평균가격을 dplyr패키지를 활용하여 구하고자 한다. 실행 함수를 작성하고, 거래건수와 평균 가격을 적으시오.

# 연습문제 10

- apt 데이터 프레임을 tibble 데이터 셋으로 변환하여 사용하고자 한다. 적용할 함수를 적고, 이의 장점을 서술하시오.

  - 함수명:

  - 장점:

# 요약

- 데이터 불러오기와 저장하기
  - 데이터의 종류와 불러오기(저장하기)
  - 내장 데이터 불러오기
  - 작업경로(폴더) 확인 및 변경
  - 외장 데이터 불러오기와 저장하기
    - 텍스트 파일(.txt, .csv, ...)
    - 엑셀 스프레드 시트(. xls, .xlsx)
- 데이터 마이닝 기초
  - 데이터 탐구하기
  - 데이터 정렬하기
  - 데이터 병합하기
  - 데이터 변환하기
  - 데이터 추출하기
  - 기타 유용한 함수들: (....) with, attach, detach
- dplyr 패키지를 활용한 데이터 마이닝
  - dplyr 패키지 소개
  - 추출하기: select()
  - 특정 조건에 맞는 데이터 추출하기: filter()
  - 정렬하기: arrange()
  - 변수명 변환하기: rename()
  - 데이터 수정 및 변형: mutate(), transmute()
  - 집단별 데이터 분할하기: group_by()
  - 데이터 마이닝 간결하게 수행하기: %>% (파이프 연산자)
  - 데이터 요약하기: summarise()
  - 데이터 수정하기: [ ], transform(), recode()
  - 기타 함께 사용하는 유용한 함수들: distinct(), between(), row_number(), n()
  - 데이터 병합: join()
  - tbl_df() 소개

# 끝

- 질의와 토의(Question & Discussion)
  - 이번 강의 내용을 시청하고, 실행하면서 궁금한 점이나 어려운 점에 대하여 토의해봅시다.

- 다음 주 강의주제
  - 그래프와 ggplot2 패키지