	단위별 학습내용 (Week13)
wk13-1	군집분석과 유사성척도
wk13-2	계층적 군집분석
wk13-3	비계층적 군집분석

Wk13-1 : 군집분석과 유사성척도

1. 군집분석

• 군집분석은 비지도학습(Unsupervised Learning) : 속성변수들의 특징으로 그룹화

모형화	특징	내용	적용기법
예측	• 타겟변수 값이 주어지는 경우 (supervised learning) • 변수간의 관계	주어진 데이터를 기반으로 모델을 만든 후, y값을 예측 (y=continuous value)	• 다중회귀분석 • 주성분 회귀분석 • 부분최소자승법 • 신경망
분류		학습표본을 기반으로 분류 규칙을 생성. 분류규칙의 성능을 검증하기 위해 실제 범주와 추정된 범주를 비교 (y=0/1 혹은 다범주)	• K-인접기법 • 로지스틱 회귀모형 • 의사결정나무 • 선형판별분석 • 서포트벡터머신
군집	• 타겟변수 값이 없는 경우 (unsupervised learning) • 개체간의 관계	주어진 데이터 (X변수들)의 속성으로 군집화	• 계층형 군집 분석 • k-means
연관규칙		연관성 있는 변수관계 도출 (동시 발생 빈도 분석)	• 연관규칙 분석

1. 군집분석

• 군집분석(cluster analysis)이란, 유사한 속성을 가진 객체들을 군집(cluster)으로 나누는(묶어주는) 데이터마이닝 기법

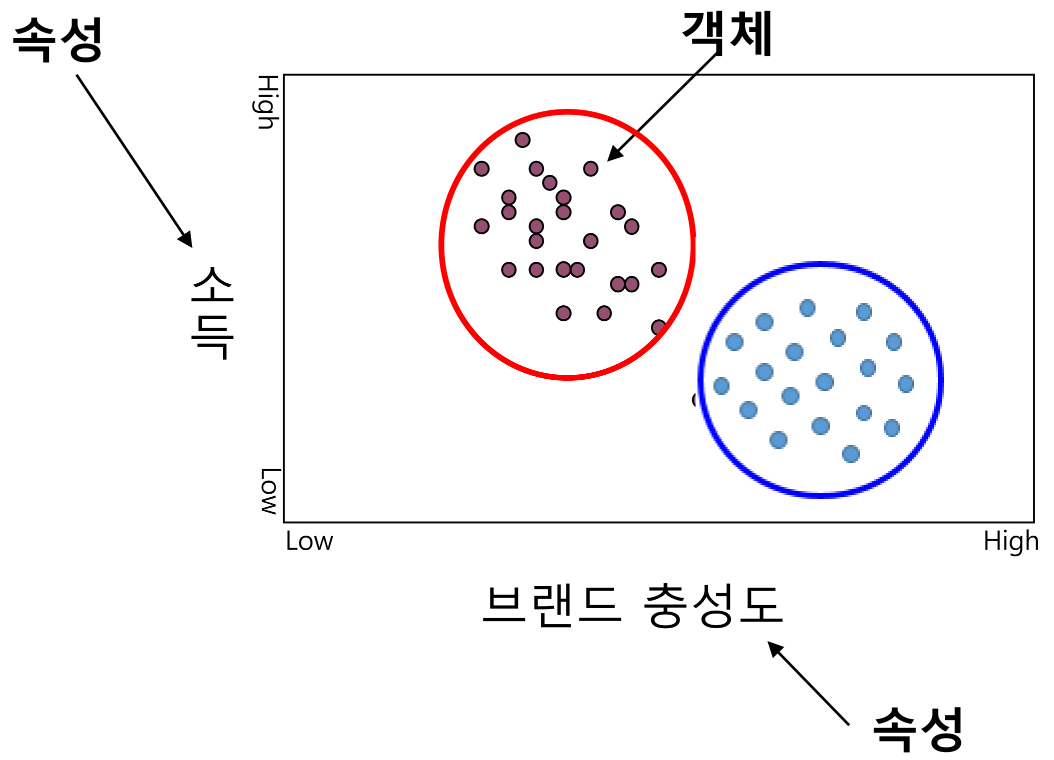

▪ 예제 : 고객들의 구매패턴를 반영하는 속성들에 관한 데이터가 수집된다고 할 때

=> 군집분석을 통해 유사한 구매패턴을 보이는 고객들을 군집화하고 판매전략을 도출

3. 군집분석 종류

- 군집분석의 방법은 (1) 계층적 방법과 (2) 비계층적 방법으로 구분

(1) 계층적 군집 (Hierarchical Clustering)

- 사전에 군집 수 k를 정하지 않고 단계적으로 군집 트리를 제공

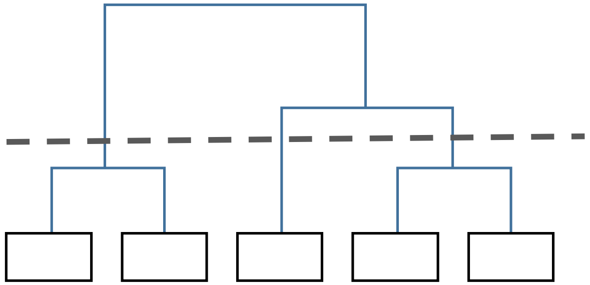

(2) 비계층적 군집 (Non-hierarchical Clustering)

- 사전에 군집 수 k를 정한 후 각 객체를 k개 중 하나의 군집에 배정

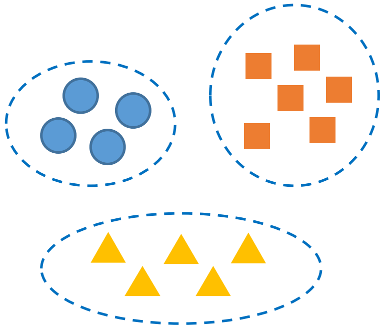

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

군집분석

- 유사성척도의 계산 -

1. 유사성 척도

- 객체 간의 유사성 정도를 정량적으로 나타내기 위해서 척도가 필요
  - 거리 (distance) 척도

    - 거리가 가까울수록 유사성이 크다. 거리가 멀수록 유사성이 적어짐

  - 상관계수척도

    - 객체간 상관계수가 클수록 두 객체의 유사성이 커짐

2. 거리 척도

- 객체 i의 p차원 공간에서의 좌표는 다음과 같은 열벡터로 표현

  - p개의 속성을 가진 객체 i에 대하여, j번째 속성은 X_{ji} 으로 표현

$$x_i = (X_{1i}, X_{2i}, \cdots, X_{pi})^T \quad i = 1, \cdots, n$$

- 유클리디안 거리

$$d_{ij} = d(x_i, x_j) = \sqrt{\sum_{k=1}^{p} \left| X_{ki} - X_{kj} \right|^2}$$

$$Distance = \sqrt{(x_{12} - x_{11})^2 + (x_{21} - x_{22})^2}$$

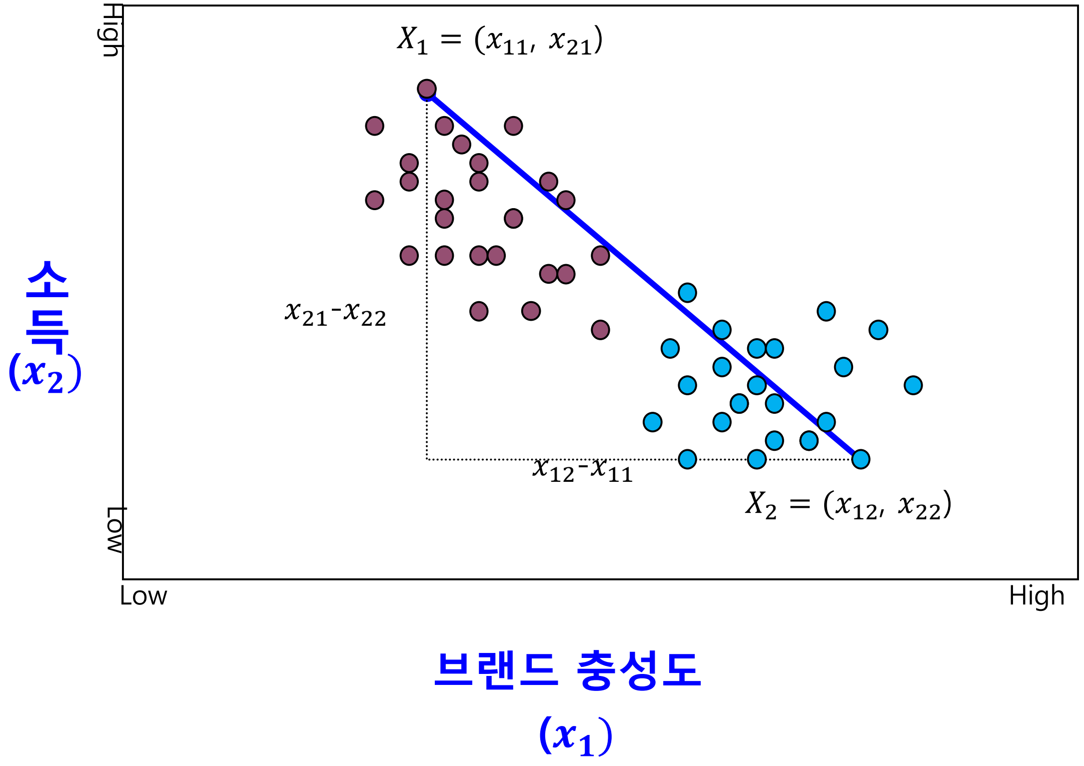

3. 유클리디안 거리

- 유클리디안 거리(Euclidean distance)

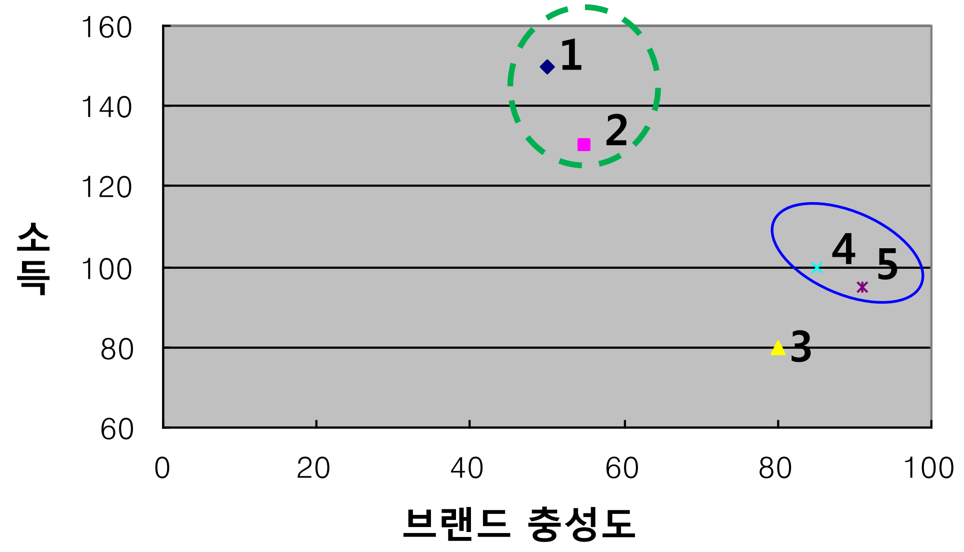

$$d_{12} = d_{21} = \sqrt{(150-130)^2+(50-55)^2} = 20.6$$

데이터

ID	소득	브랜드 충성도
1	150	50
2	130	55
3	80	80
4	100	85
5	95	91

ID	**1**	2	3	4	5
1	0.0				
2	**20.6**	0.0			
3	76.2	55.9	0.0		
4	61.0	42.4	20.6	0.0	
5	68.6	50.2	18.6	7.8	0.0

- (4와 5번)이 가장 가까움

3. 유클리디안 거리

- 거리(distance)계산 함수 : dist(데이터, method= ,)

```
# lec13_1_clus.R
# Clustering
# Distance measure

# similarity measures - distance
m1 <- matrix(
  c(150, 50, 130, 55, 80, 80, 100, 85, 95, 91),
  nrow = 5,
  ncol = 2,
  byrow = TRUE)
# m1 is a matrix
m1
is.data.frame(m1)
# m1 is defined as dataframe
m1<-as.data.frame(m1)
```

데이터 생성 (m1, 5x2 행렬)

```
> m1
     [,1] [,2]
[1,]  150   50
[2,]  130   55
[3,]   80   80
[4,]  100   85
[5,]   95   91
```

m1을 data frame으로 저장

```
# 1. Euclidean distance
D1 <- dist(m1)
D1
```

```
> D1 <- dist(m1)
> D1
         1        2        3        4
2 20.61553
3 76.15773 55.90170
4 61.03278 42.42641 20.61553
5 68.60029 50.20956 18.60108  7.81025
```

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

3. 유클리디안 거리

- 거리계산 옵션

```
help("dist")
```

Distance Matrix Computation

Description

This function computes and returns the distance matrix computed by using the specified distance measure to compute the distances between the rows of a data matrix.

Usage

```
dist(x, method = "euclidean", diag = FALSE, upper = FALSE, p =

as.dist(m, diag = FALSE, upper = FALSE)
## Default S3 method:
as.dist(m, diag = FALSE, upper = FALSE)

## S3 method for class 'dist'
print(x, diag = NULL, upper = NULL,
      digits = getOption("digits"), justify = "none",
      right = TRUE, ...)

## S3 method for class 'dist'
as.matrix(x, ...)
```

Arguments

`x`	a numeric matrix, data frame or `"dist"` object.
`method`	the distance measure to be used. This must be one of `"euclidean"`, `"maximum"`, `"manhattan"`, `"canberra"`, `"binary"` or `"minkowski"`. Any unambiguous substring can be given.

4. 그 외 거리 척도

- **민코프스키 거리(Minkowski distance)**

  - 유클리디안 거리의 일반화된 방법 (m=2 일 때는 유클리디안 거리와 동일)

$$d(x_i, x_j) = (\sum_{k=1}^{p} \left|X_{ki} - X_{kj}\right|^m)^{1/m}$$

- **마할라노비스 거리(Mahalanobis distance)**

  - 변수 간의 상관 관계가 존재할 때 사용

$$d(x_i, x_j) = \sqrt{(x_i - x_j)^T S^{-1}(x_i - x_j)}$$

$$S = \begin{bmatrix} s_1^2 & s_{12} & \cdots & s_{1p} \\ s_{21} & s_2^2 & & s_{2p} \\ \vdots & & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_p^2 \end{bmatrix}$$

$$s_{ab} = \frac{\sum_i (X_{ai} - \overline{X_a})(X_{bi} - \overline{X_b})}{n-1}$$

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

4. 그 외 거리 척도

- **민코프스키 거리(Minkowski distance)**

: dist(data(or matrix), method="minkowski", p=3)

```
# 2. Minkowski distance
D2<- dist(m1, method="minkowski", p=3)
D2
```

민코프스키 거리

```
> D2<- dist(m1, method="minkowski", p=3)
> D2
          1         2         3         4
2 20.103629
3 71.790544 52.002096
4 55.164795 37.797631 20.103629
5 61.735957 44.736068 16.757812  6.986368
```

유클리디안 거리

```
> D1 <- dist(m1)
> D1
         1        2        3        4
2 20.61553
3 76.15773 55.90170
4 61.03278 42.42641 20.61553
5 68.60029 50.20956 18.60108  7.81025
```

민코프스키 계산식에서 p=2이면 유클리디안거리와 동일

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

5. 상관계수를 척도로 사용

- 또 다른 유사성 척도로 객체 간의 상관계수를 사용
  - 상관계수가 클수록 두 객체의 유사성이 크다고 추정

- 객체 i 와 객체 j 간의 표본상관계수는 다음과 같이 정의

$$sim(x_i, x_j) = r_{ij} = \frac{\sum_{k=1}^{p}(X_{ki} - m_i)(X_{kj} - m_j)}{\sqrt{\sum_{k=1}^{p}(X_{ki} - m_i)^2}\sqrt{\sum_{k=1}^{p}(X_{kj} - m_j)^2}}$$

- 이때 m_i는 객체 i의 평균값으로 다음과 같음

$$m_i = \frac{1}{p}\sum_{k=1}^{p} X_{ki}$$

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY

5. 상관계수

- 상관계수측정(cor)

```
# 3. correlation coefficient
m2 <- matrix(
   c(20, 6, 14, 30, 7, 15, 46, 4, 2),
   nrow = 3, ncol = 3, byrow = TRUE,
   dimnames = list(
     c("obs1", "obs2", "obs3"),
     c("age", "exp", "time")))

m2

# correlation between Obs1~Obs2
cor(m2[1,],m2[2,])
# correlation between Obs1~Obs3
cor(m2[1,],m2[3,])
```

데이터 생성 (3x3 matrix)

```
> m2
     age exp time
obs1  20   6   14
obs2  30   7   15
obs3  46   4    2
```

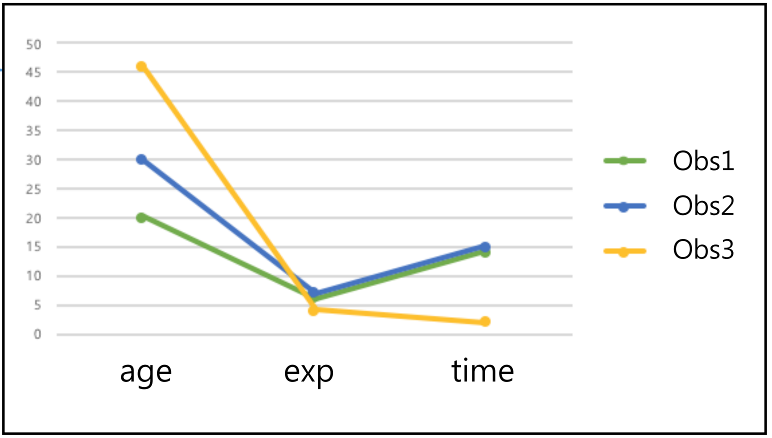

상관계수 측정

```
> # correlation between Obs1~Obs2
> cor(m2[1,],m2[2,])
[1] 0.9673518
> # correlation between Obs1~Obs3
> cor(m2[1,],m2[3,])
[1] 0.7984081
```

객체1(obs1)과 객체2의 유사성이
객체1(obs1)과 객체3간의 유사성보다 크다 (0.9674 > 0.7984)

POSTECH
POHANG UNIVERSITY OF SCIENCE AND TECHNOLOGY